Propuesta de proyecto: factores asociados a la diabetes en la población adulta

Yago Raúl Huerta Orozco | Diplomado de Minería de Datos y Técnicas Estadísticas, Módulo 3 | FES Acatlán, UNAM

1. Motivación

La diabetes es una de las enfermedades crónico-degenerativas más frecuentes en la población adulta y una de las principales causas de complicaciones graves, como enfermedad cardiovascular, renal y pérdida de la visión. Mi interés por el tema es tanto académico como personal: llevo una vida muy sedentaria y me preocupa mi propio riesgo de desarrollarla. Entender qué características de las personas se relacionan con la enfermedad, y qué tan común es según el perfil, permite dimensionar el problema y reconocer qué hábitos y condiciones conviene vigilar o modificar a tiempo.

2. Problema de investigación

¿Cuál es la prevalencia de la diabetes en la población adulta del conjunto de datos y qué factores demográficos, de estilo de vida y clínicos se asocian con que una persona la padezca o tenga mayor riesgo de padecerla? En particular, se busca identificar si variables como la edad, el sexo, la ciudad de residencia, el índice de masa corporal (IMC) y los hábitos de vida (incluida la actividad física, si la base la contempla) diferencian a los individuos con diabetes de los que no la tienen. Al tratarse de datos observacionales, el estudio hablará de factores asociados y no de relaciones causales comprobadas.

3. Resultado esperado

Se espera obtener un perfil descriptivo de la población estudiada, con la prevalencia de la enfermedad en general y por grupos (edad, sexo, ciudad, rangos de IMC); un conjunto de variables que muestren una asociación clara con la diabetes, respaldado por visualizaciones y medidas estadísticas; y conclusiones interpretables sobre qué condiciones y hábitos están más ligados al riesgo. Estos hallazgos servirán de base para las técnicas de minería de datos que se vean en el módulo y para reflexionar sobre qué cambios de estilo de vida serían más relevantes para reducir el riesgo.

4. Detalles preliminares de la base de datos

Se empleará el conjunto *Diabetes Risk Prediction* (Mansi Aggarwal, Kaggle; https://www.kaggle.com/datasets/mansiaggarwal88/diabetes-risk-prediction), archivo *diabetes_risk.csv* (1.54 MB). Contiene **15,000 registros y 19 columnas** demográficas, de estilo de vida y clínicas, por lo que supera el mínimo de (400, 10). Incluye varias variables categóricas (por ejemplo, sexo, con 51% hombres, 48% mujeres y 1% otro, y ciudad de residencia en India, con Mumbai 15% y Delhi 12%) y variables numéricas como la edad (18 a 95 años, con mayor concentración en adultos de mediana edad) y el IMC (valores desde 15). Cuenta además con un identificador por paciente. En la exploración inicial se revisarán el resto de las variables, la variable categórica que indica el riesgo o diagnóstico de diabetes, los valores faltantes o atípicos y el balance de clases. Los datos son de carácter sintético, por lo que los resultados se interpretarán con fines académicos.