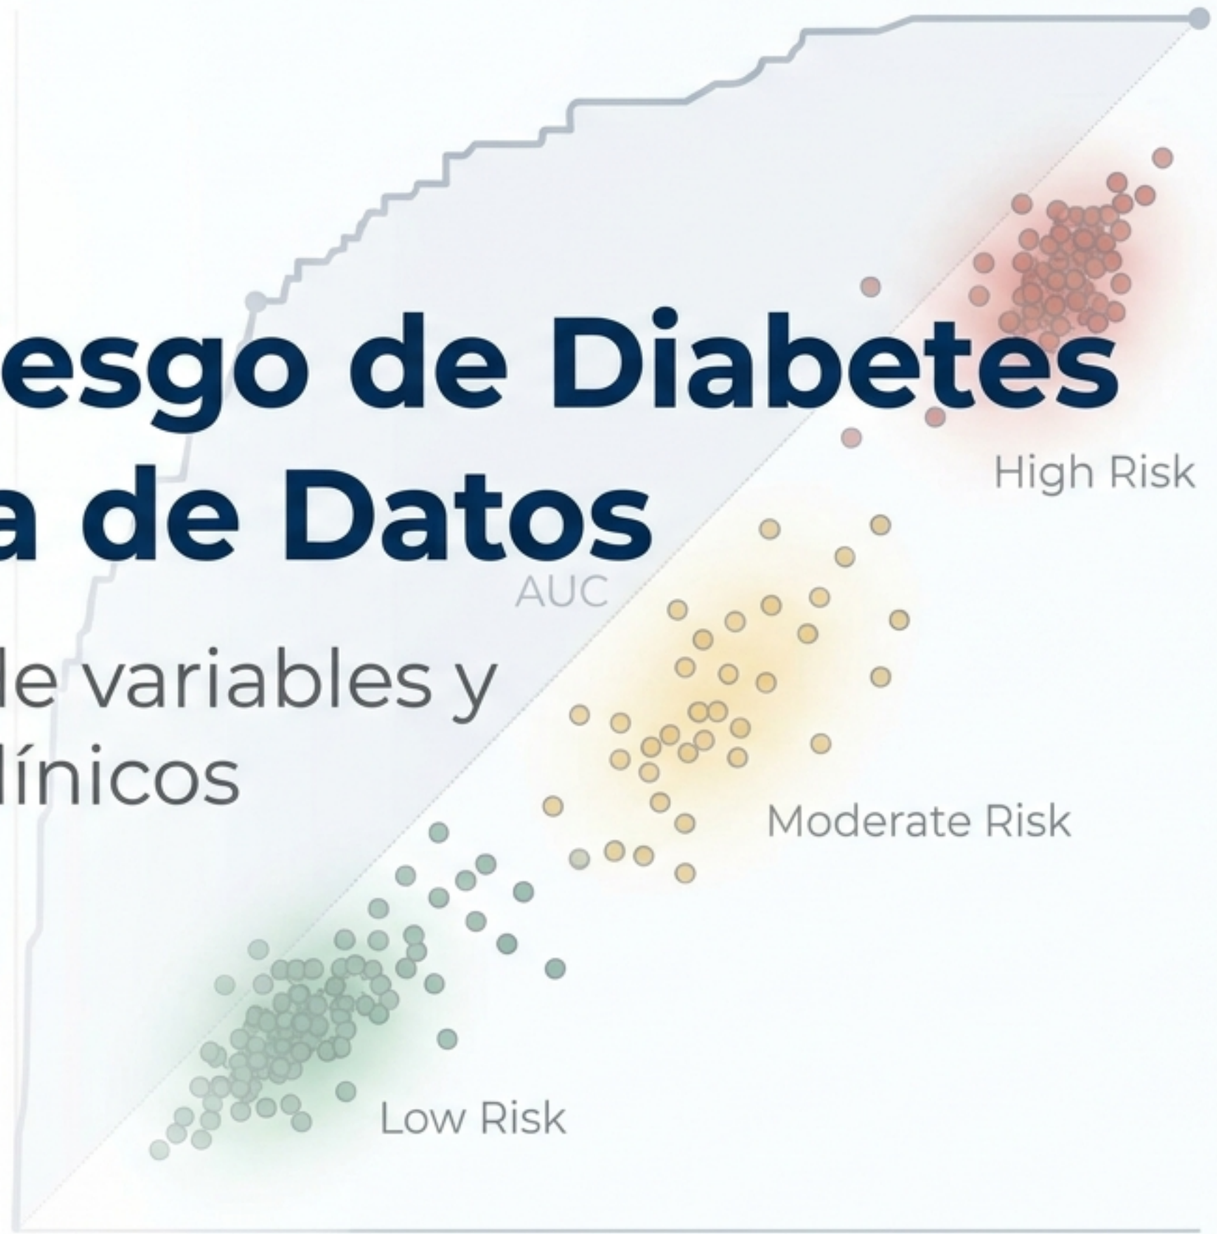
Predicción del Riesgo de Diabetes mediante Minería de Datos

Clasificación, importancia de variables y segmentación de perfiles clínicos

Yago Raúl Huerta Orozco



Gemini Notebook

Contexto Global

La diabetes es un reto crítico: afecta a **830 millones** de personas en el mundo (OMS, 2024).

Su detección oportuna mediante análisis de datos observacionales puede optimizar drásticamente los recursos de salud pública.

Objetivos del Proyecto

1.

Describir asociaciones

Identificar factores de estilo de vida y clínicos vinculados al riesgo de diabetes.

2.

Comparar clasificadores

Evaluar modelos predictivos (**Regresión Logística**, **Naive Bayes**, **SVM**) y el impacto real de los marcadores metabólicos.

3.

Segmentar perfiles

Descubrir grupos clínicos subyacentes mediante un enfoque no supervisado (K-Means).

Gemini Notebook

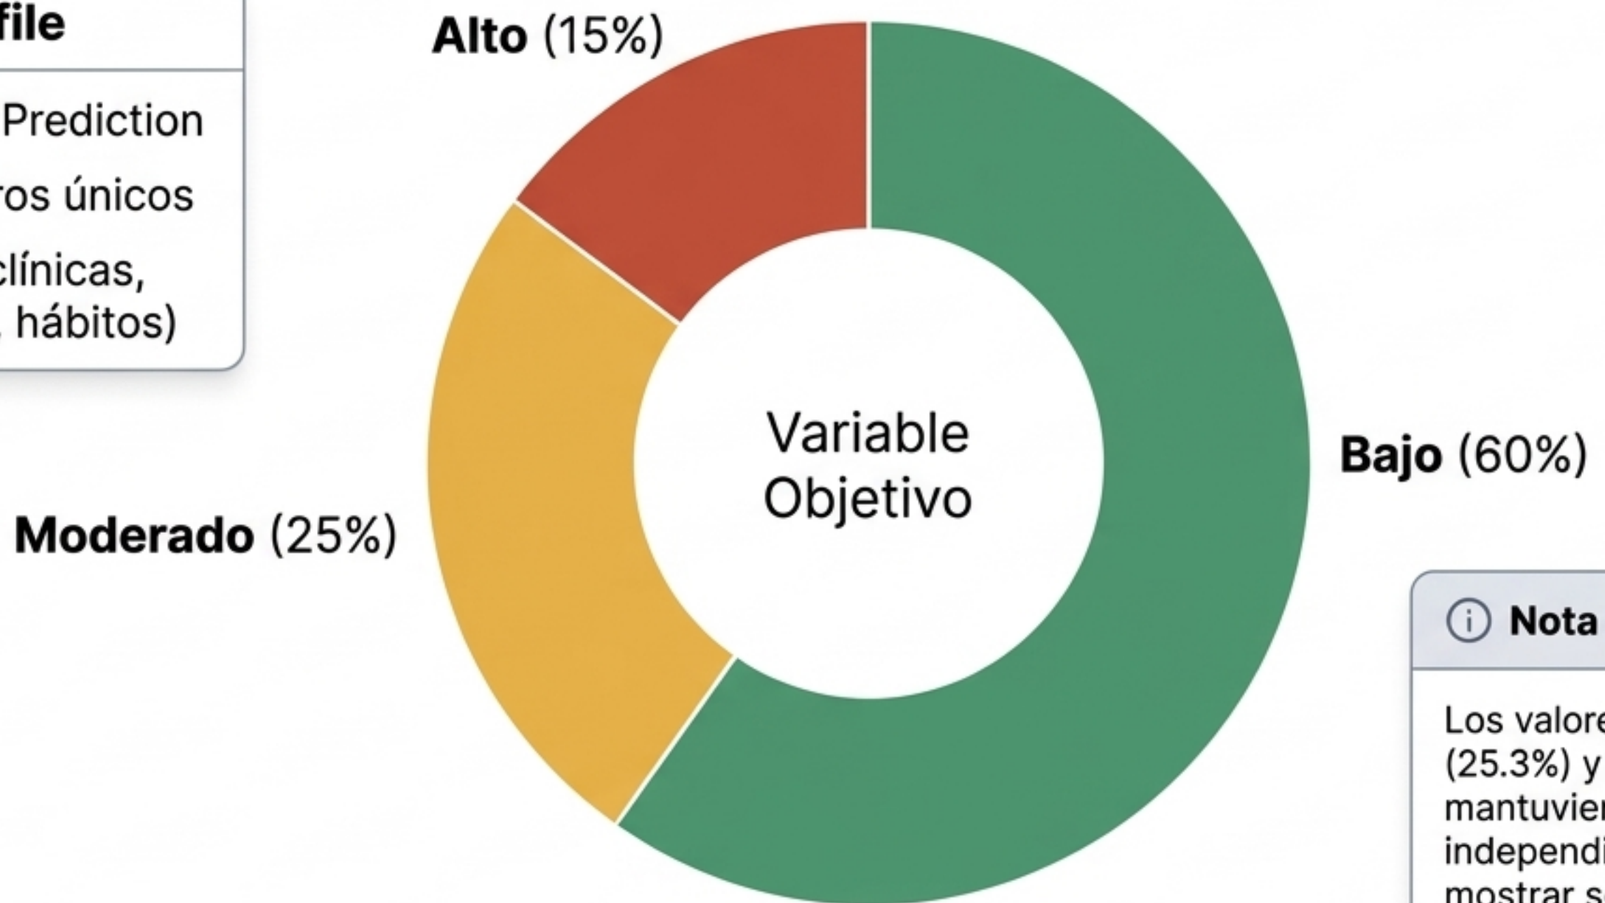
Radiografía de los Datos: 15,000 registros sintéticos y desbalance de clases

Dataset Profile

Diabetes Risk Prediction

15,000 registros únicos

19 variables (clínicas, demográficas, hábitos)



Nota de Preprocesamiento

Los valores faltantes en alcohol (25.3%) y tabaquismo (3.1%) se mantuvieron como categoría independiente ("Sin dato") al no mostrar sesgo estadístico hacia ningún nivel de riesgo ($p > 0.05$).

Gemini Notebook

Arquitectura del Análisis: Desde el preprocesamiento hasta el modelado

Fase 1: Preprocesamiento

- Imputación de faltantes ('Sin dato')
- Codificación One-Hot (categóricas)
- Estandarización StandardScaler (numéricas)

Fase 2: Modelado Supervisado

- Partición 70/30 (estratificada, semilla 42)
- **Regresión Logística Multinomial**
- **Naive Bayes Gaussiano**
- **SVM (Núcleo RBF)**
- Validación cruzada 5-fold

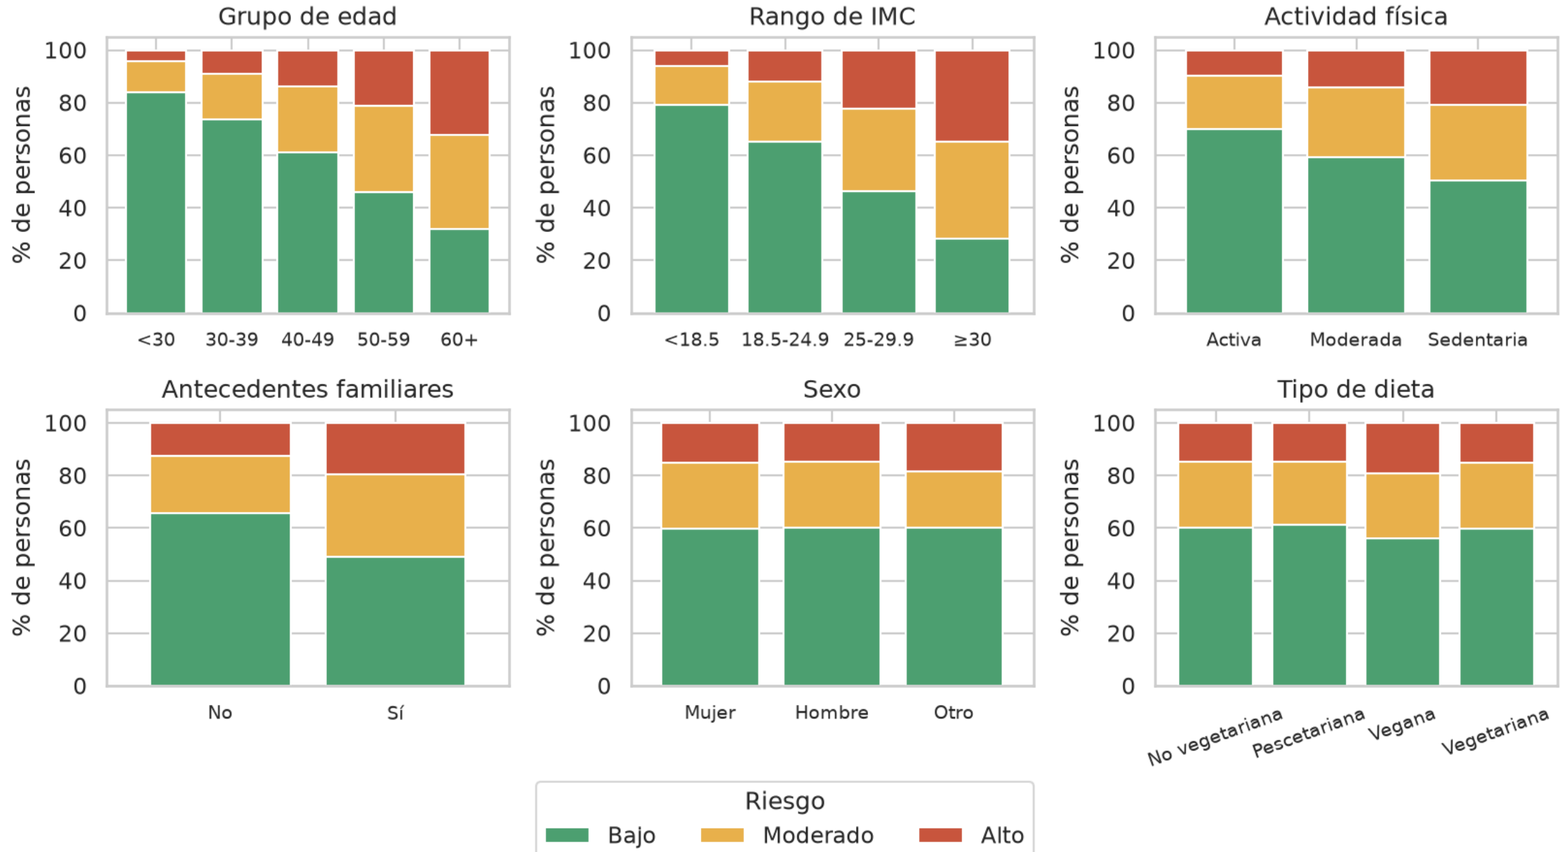
Fase 3: Modelado No Supervisado

- Algoritmo K-Means
- Exclusivo para 6 variables clínicas
- Sin etiqueta de riesgo

Decisión Analítica Crucial: Todos los modelos supervisados se evaluaron en dos escenarios paralelos: **Con** y **Sin** mediciones metabólicas (Glucosa y HbA1c).

Gemini Notebook

Edad, obesidad y sedentarismo muestran la mayor asociación con el riesgo alto



Edad

El **riesgo alto** sube del **4.1%** (<30 años) al **32.4%** (60+ años).

IMC

Crece del **5.9%** en bajo peso al **34.7%** en obesidad (IMC ≥ 30).

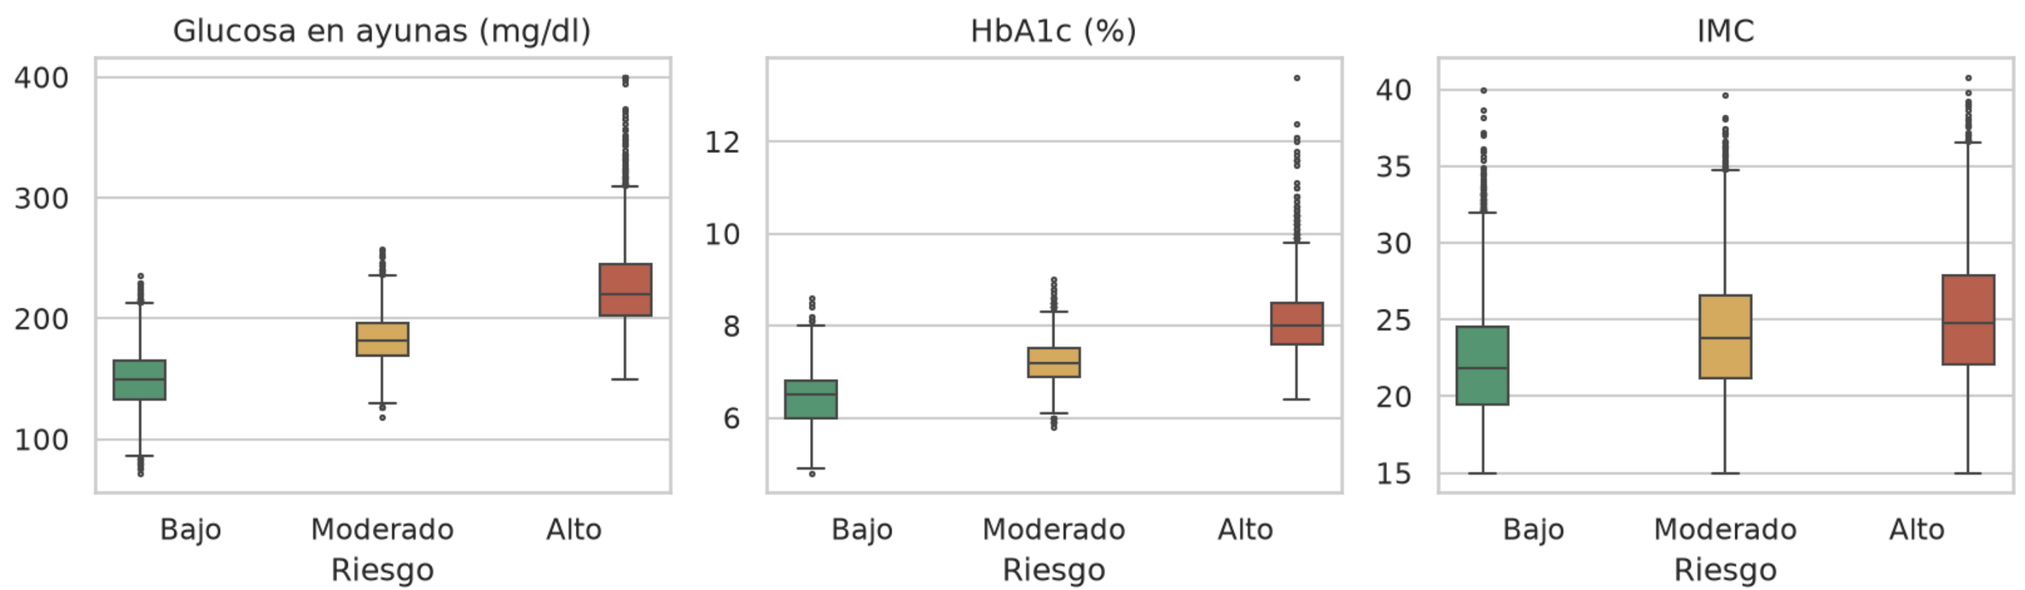
Estilo de vida y genética

Sedentarios: **21.0%** de riesgo alto (vs **9.8%** activos). Con antecedentes familiares: **19.7%** (vs **12.5%**).

Sin asociación

Sexo, dieta, tabaquismo y alcohol: **p > 0.3**. Las barras son casi idénticas entre categorías.

Glucosa y HbA1c separan casi perfectamente los niveles de riesgo



Glucosa en ayunas

La media pasa de **148 mg/dl** (riesgo bajo) a **226 mg/dl** (riesgo alto).

HbA1c

La media sube de **6.4%** (riesgo bajo) a **8.1%** (riesgo alto).

Insight clínico-estadístico

Correlación de **0.91**: miden casi lo mismo, lo que penaliza el supuesto de independencia de Naive Bayes.

Sin indicadores metabólicos, el desempeño de todos los modelos colapsa

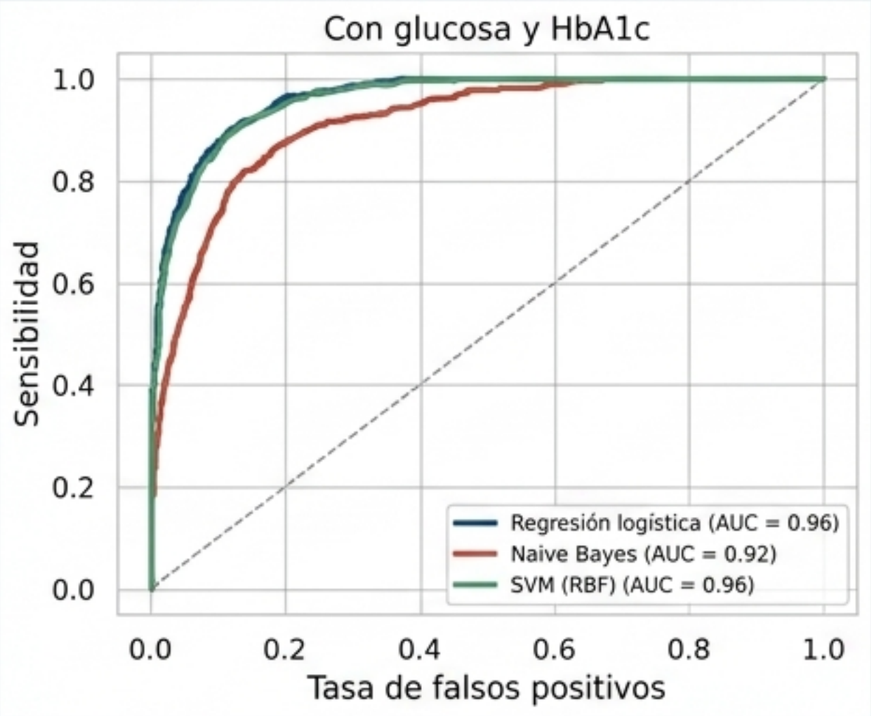
	Regresión Logística	Naive Bayes	SVM (RBF)
Escenario 1: Con Glucosa y HbA1c	AUC: **0.91** Exactitud: **0.76** (Líder)	AUC: **0.87** Exactitud: **0.72**	AUC: **0.91** Exactitud: **0.75**
Escenario 2: Sin Glucosa ni HbA1c	AUC: **0.69** Exactitud: **0.52**	AUC: **0.65** Exactitud: **0.53**	AUC: **0.69** Exactitud: **0.53**

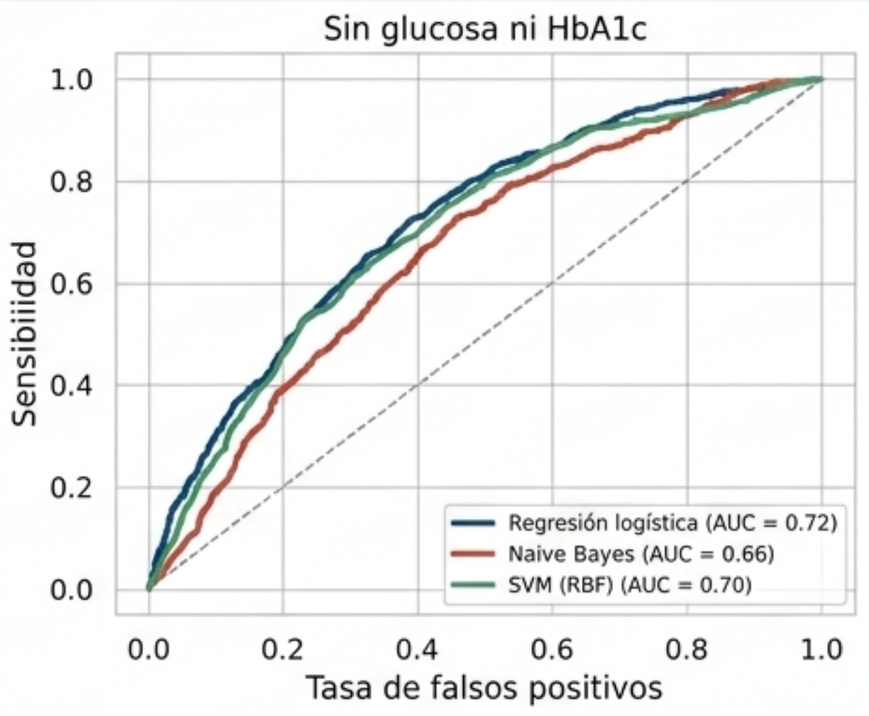
CAÍDA LIBRE

Sin las dos métricas de laboratorio, el modelo predice apenas mejor que el azar.

Gemini Notebook

Las variables de estilo de vida por sí solas no sirven como herramienta de detección





Con variables clínicas

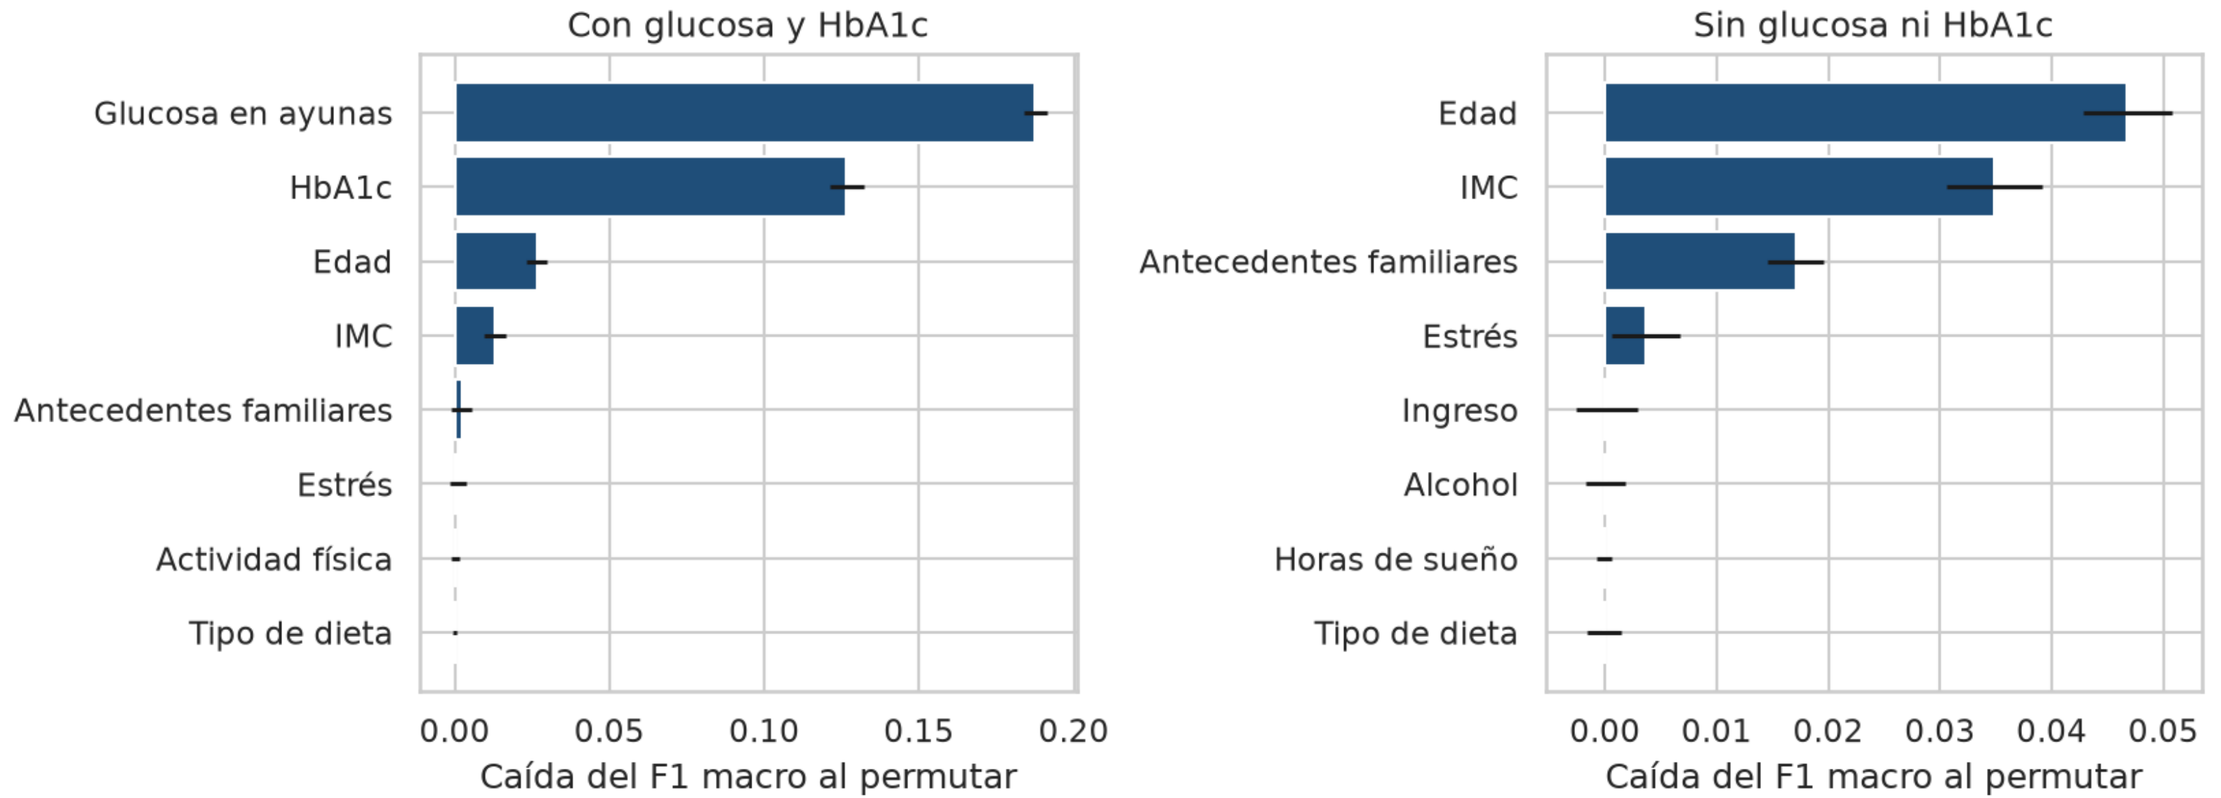
- **AUC alcanza 0.96 (LogReg/SVM)** aislando el Riesgo Alto.
- **Alta** sensibilidad (0.88) con precisión aceptable (0.59).

Sin variables clínicas

- El **AUC general cae a 0.72**.
- El problema real: **La precisión se desploma al 26%**.
- **Insight:** Sin glucosa ni HbA1c, **3 de cada 4 alertas de alto riesgo son falsas positivas**.

Gemini Notebook

El desplazamiento de la importancia: de marcadores biológicos a demográficos



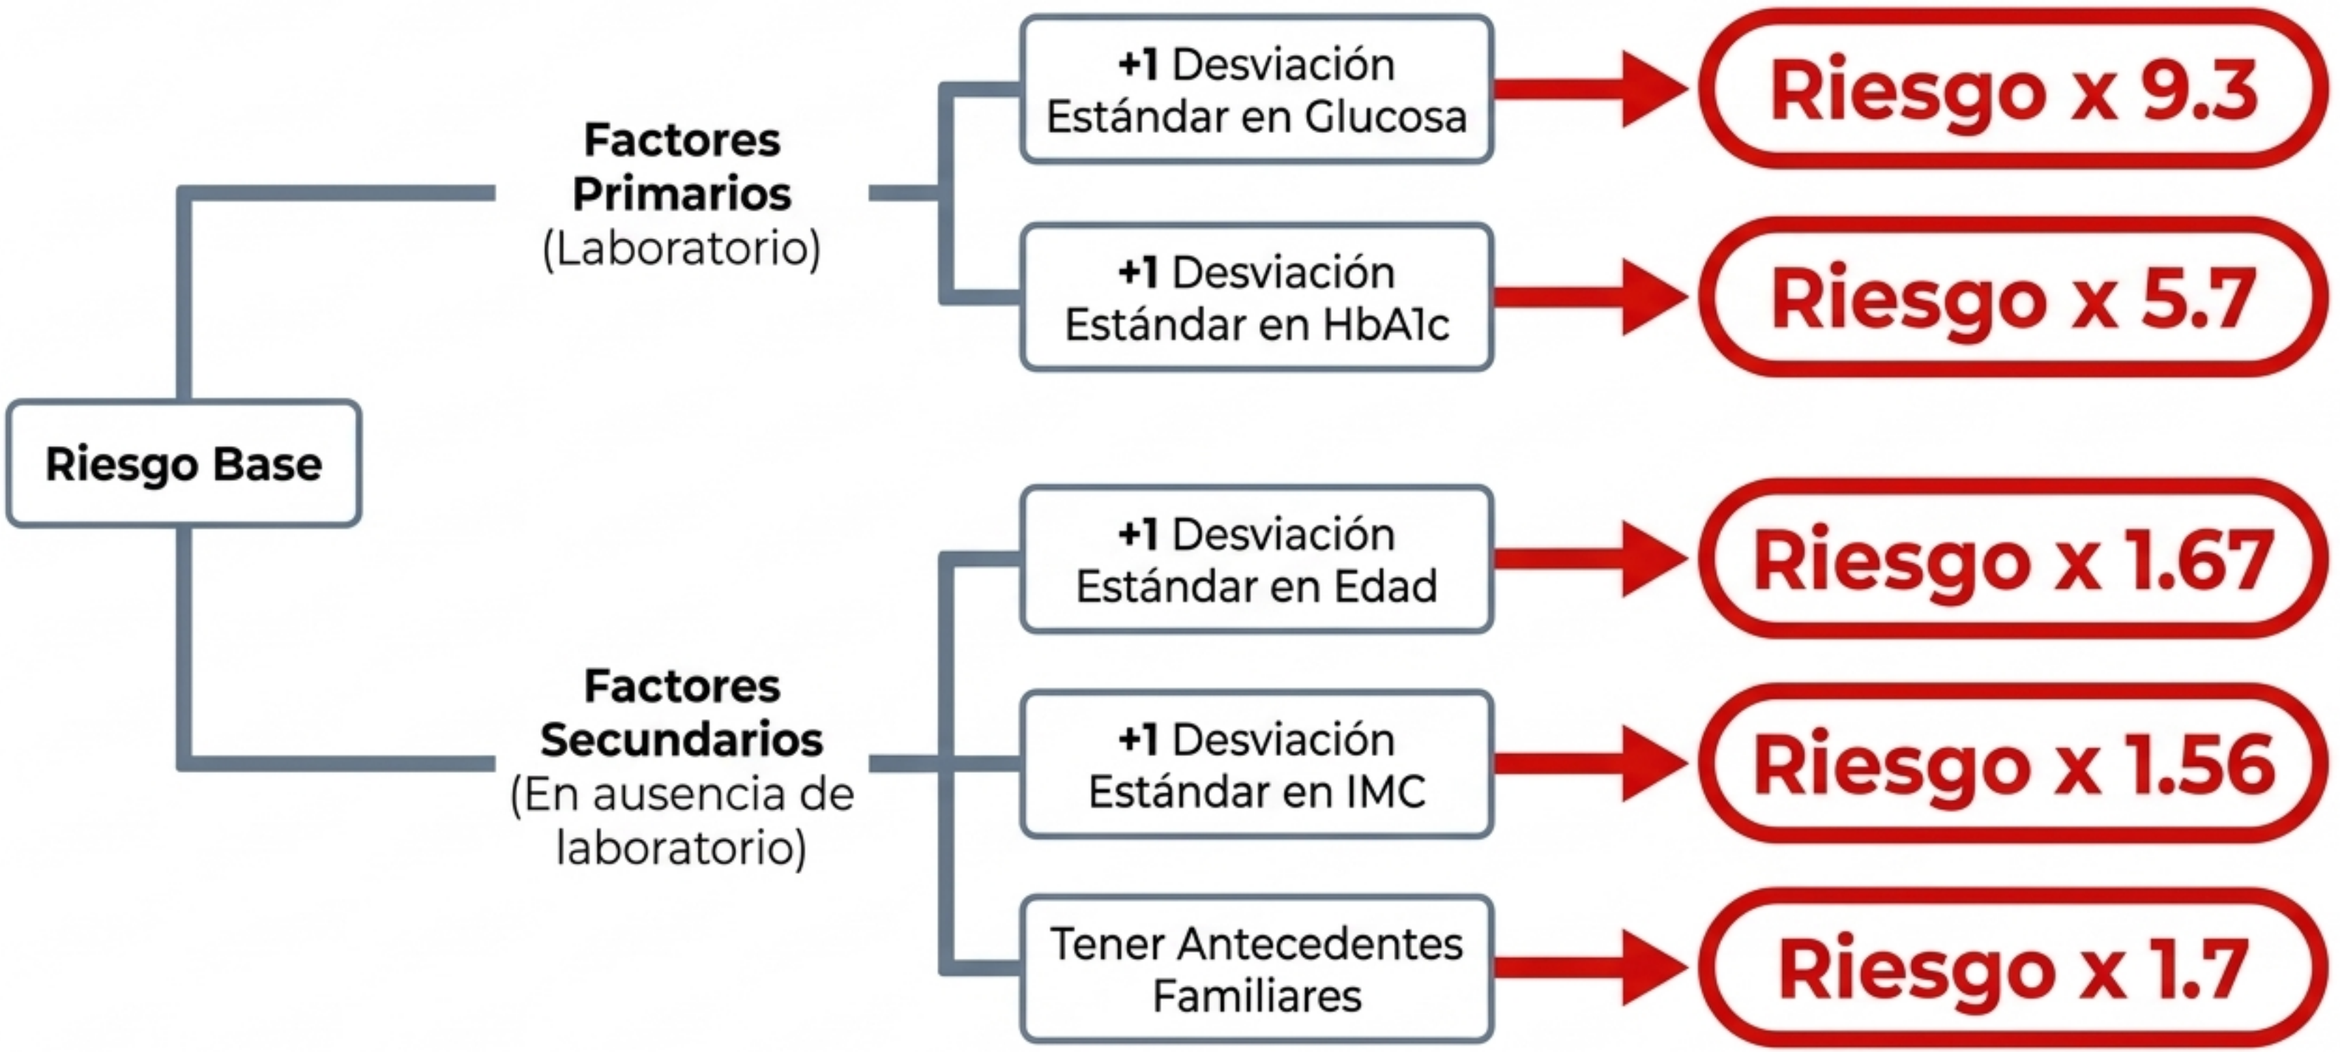
Con glucosa y HbA1c

El riesgo lo dominan la glucosa (caída del F1: **0.19**) y la HbA1c (**0.13**). Edad (0.03) e IMC (0.01) aportan muy poco.

Sin glucosa ni HbA1c

La señal pasa a edad (**0.05**), IMC (**0.03**) y antecedentes familiares (**0.02**). Las demás variables rondan el cero.

Explicabilidad del modelo: **Multiplicadores del Riesgo Alto (LogReg)**



*Multiplicadores basados en coeficientes de la Regresión Logística Binaria.

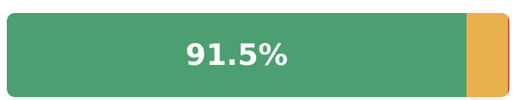
Gemini Notebook

K-Means identifica 4 perfiles clínicos alineados con el riesgo

Perfil 1: Jóvenes sin alteraciones

29.1% de la población

- Edad media 35 años, IMC 20.5.
- Glucosa (141) y presión (129) más bajas de los cuatro grupos.

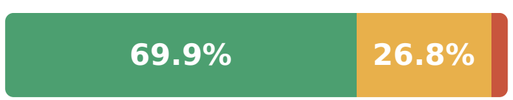


Bajo 91.5% · Moderado 8.2% · Alto 0.3%

Perfil 2: Mayores con presión elevada

32.2% de la población

- Edad media 50 años.
- Presión sistólica 144.
- Glucosa intermedia (160).



Bajo 69.9% · Moderado 26.8% · Alto 3.3%

Perfil 3: Glucemia alta

14.9% de la población

- Concentra el riesgo alto.
- Glucosa 228, HbA1c 8.2.
- 62.3% son de riesgo alto.

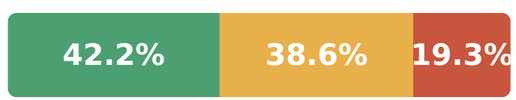


Bajo 5.3% · Moderado 32.4% · Alto 62.3%

Perfil 4: Obesidad abdominal

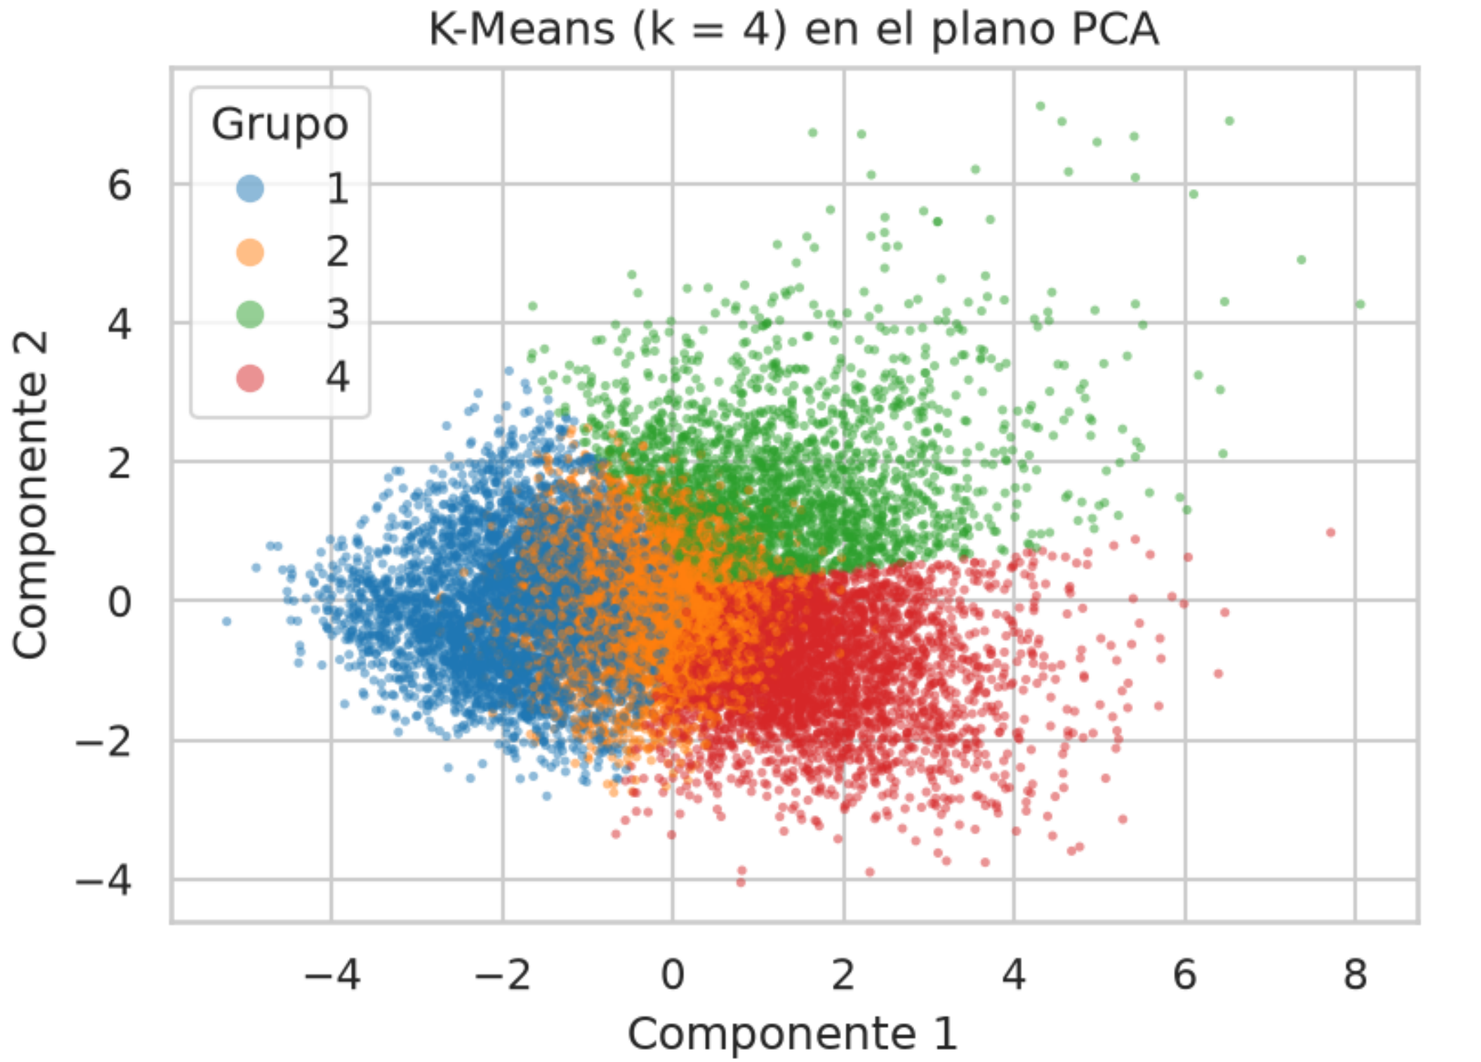
23.7% de la población

- IMC (28.3) y cintura (114 cm) más altos.
- 62% son sedentarios.
- Riesgo repartido entre los tres niveles.



Bajo 42.2% · Moderado 38.6% · Alto 19.3%

Los perfiles clínicos forman un continuo, no grupos aislados



Análisis visual

Los dos primeros componentes explican el **70.5%** de la varianza (46.0% y 24.5%). Los grupos se traslapan en el centro.

Contexto técnico

Silhouette: 0.195

Davies-Bouldin: 1.43

Las fronteras son suaves: K-Means revela tendencias clínicas graduales, no fronteras diagnósticas cerradas.

Discusión: ¿Capacidad predictiva real o artefacto de los datos sintéticos?

El Hallazgo Matemático

La **Regresión Logística** demuestra **superioridad absoluta** al lograr el mejor equilibrio entre un **altísimo desempeño (AUC 0.91)** e **interpretabilidad transparente** de los coeficientes.

Vs

La Advertencia Clínica ⚠

En este dataset sintético, el **87% de los pacientes ya superaba los criterios clínicos reales de diabetes (glucosa > 126 mg/dl)**.

Implicación Crítica

Es altamente probable que la etiqueta objetivo fuera **pre-calculada** a partir de la **Glucosa/HbA1c**. El desempeño "casi perfecto" de los modelos con estas variables es lógicamente **optimista** y **no refleja una verdadera inferencia temprana, sino una confirmación tautológica.**

Gemini Notebook

Conclusiones del Análisis

1

Variables Determinantes

El riesgo de diabetes en esta población se define de manera casi exclusiva por los niveles de **Glucosa y HbA1c.** Su poder predictivo **eclipsa** matemática y clínicamente a cualquier otro factor.

2

Marcadores Secundarios

En escenarios donde no se disponga de pruebas de laboratorio, la vigilancia combinada de **Edad**, **IMC** y **Antecedentes Familiares** ofrece la mejor (aunque limitada) señal predictiva disponible.

3

Recomendación Algorítmica

Para tareas de clasificación de riesgo clínico, la **Regresión Logística Multinomial** proporciona el modelo óptimo. Iguala a la **SVM** en potencia, supera a **Naive Bayes**, y ofrece la interpretabilidad necesaria para decisiones médicas.

Gemini Notebook