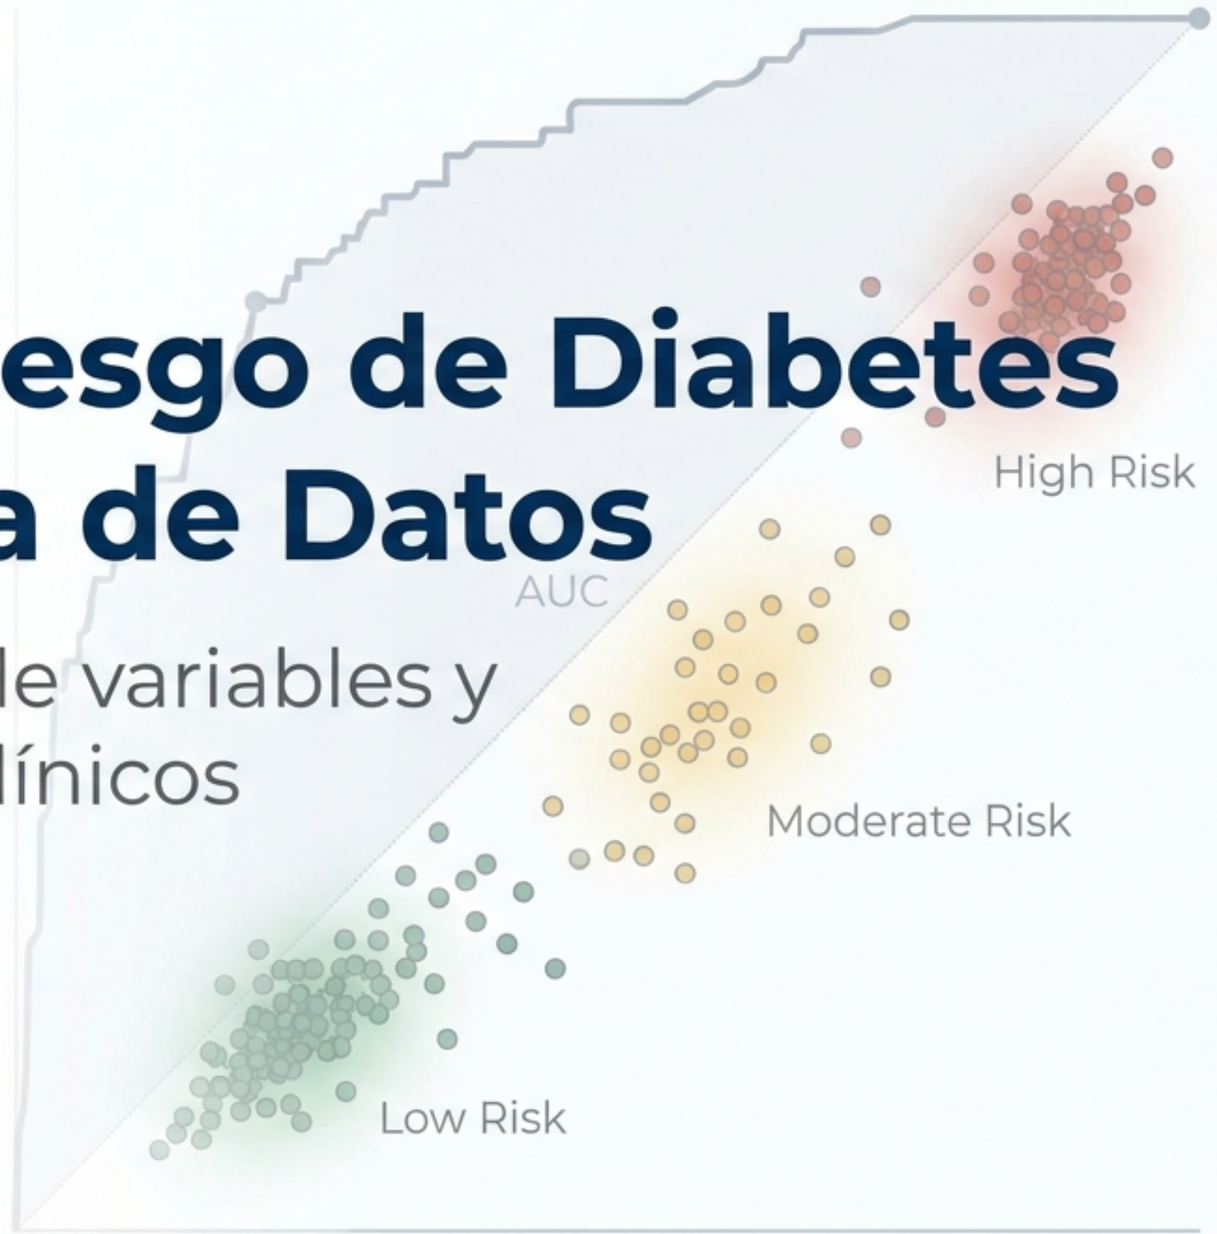
# Predicción del Riesgo de Diabetes mediante Minería de Datos

## Clasificación, importancia de variables y segmentación de perfiles clínicos

Yago Raúl Huerta Orozco




Gemini Notebook

## Contexto Global

La diabetes es un reto crítico: afecta a **830 millones** de personas en el mundo (OMS, 2024).

Su detección oportuna mediante análisis de datos observacionales puede optimizar drásticamente los recursos de salud pública.

# Objetivos del Proyecto

### 1.

**Describir asociaciones**

Identificar factores de estilo de vida y clínicos vinculados al riesgo de diabetes.

### 2.

**Comparar clasificadores**

Evaluar modelos predictivos (**Regresión Logística**, **Naive Bayes**, **SVM**) y el impacto real de los marcadores metabólicos.

### 3.

**Segmentar perfiles**

Descubrir grupos clínicos subyacentes mediante un enfoque no supervisado (K-Means).

Gemini Notebook

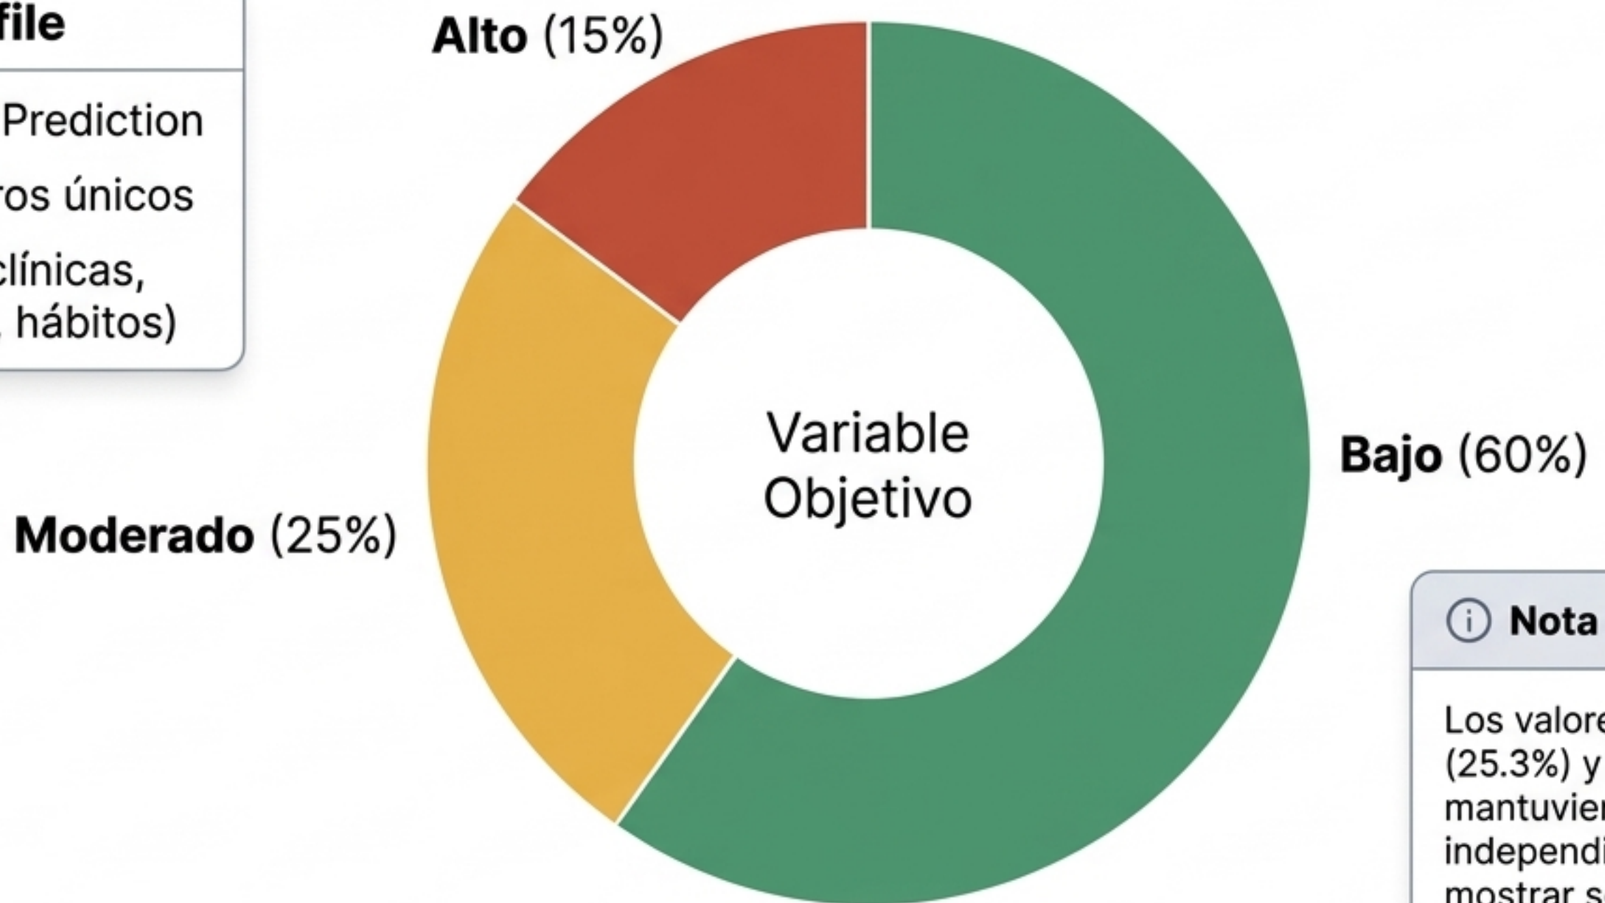
# Radiografía de los Datos: 15,000 registros sintéticos y desbalance de clases

**Dataset Profile**

Diabetes Risk Prediction

**15,000** registros únicos

**19** variables (clínicas, demográficas, hábitos)




**Nota de Preprocesamiento**

Los valores faltantes en alcohol (25.3%) y tabaquismo (3.1%) se mantuvieron como categoría independiente ("Sin dato") al no mostrar sesgo estadístico hacia ningún nivel de riesgo ($p > 0.05$).

Gemini Notebook

# Arquitectura del Análisis: Desde el preprocesamiento hasta el modelado

## Fase 1: Preprocesamiento

- Imputación de faltantes ('Sin dato')
- Codificación One-Hot (categóricas)
- Estandarización StandardScaler (numéricas)

## Fase 2: Modelado Supervisado

- Partición 70/30 (estratificada, semilla 42)
- **Regresión Logística Multinomial**
- **Naive Bayes Gaussiano**
- **SVM (Núcleo RBF)**
- Validación cruzada 5-fold

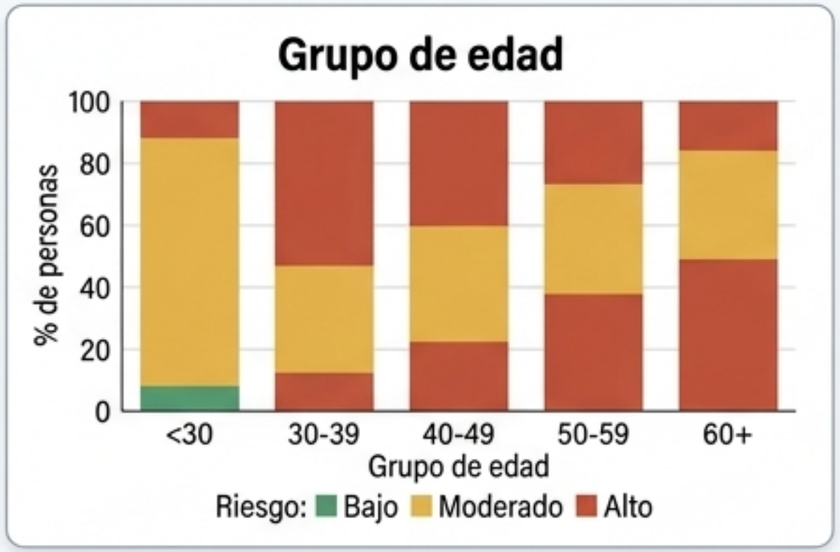
## Fase 3: Modelado No Supervisado

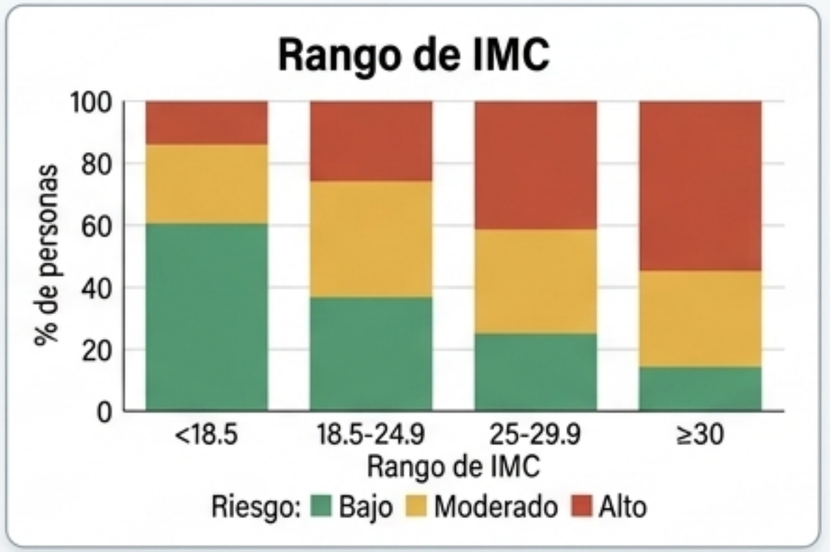
- Algoritmo K-Means
- Exclusivo para 6 variables clínicas
- Sin etiqueta de riesgo

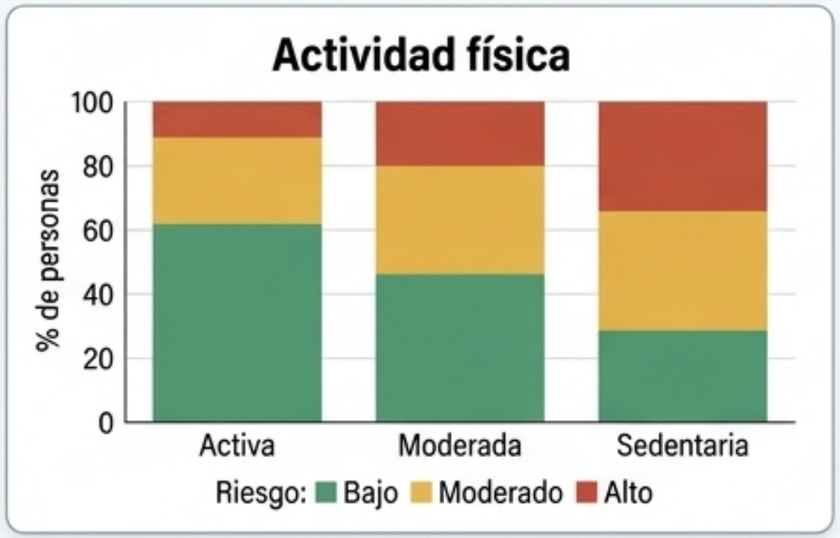
**Decisión Analítica Crucial:** Todos los modelos supervisados se evaluaron en dos escenarios paralelos: **Con** y **Sin** mediciones metabólicas (Glucosa y HbA1c).

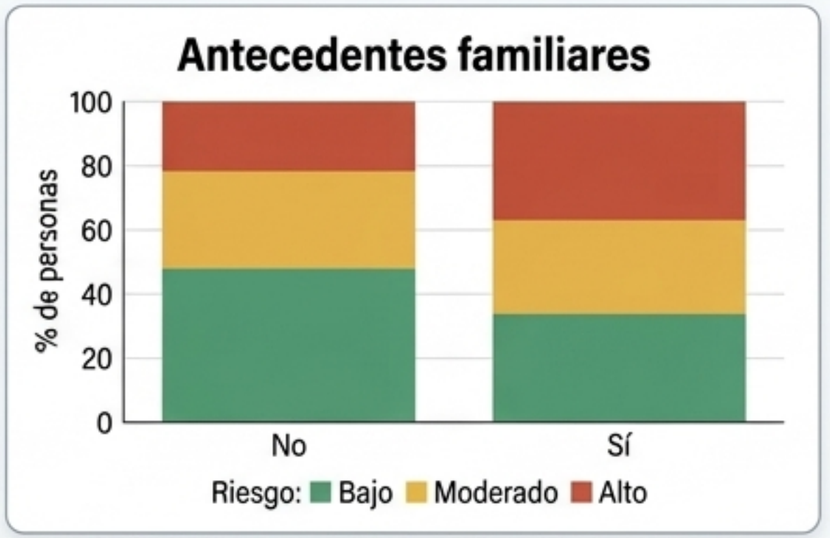
Gemini Notebook

# Edad, obesidad y sedentarismo muestran la mayor asociación con el riesgo alto




**Edad:**

El **riesgo alto** salta dramáticamente del **4.1%** (<30 años) al **32.4%** (60+ años).

**IMC:**

Crece del **5.9%** en personas con **bajo peso** al **34.7%** en personas con **obesidad** (IMC ≥ 30).

**Estilo de vida y Genética:**

Sedentarios presentan **21.0%** de riesgo alto (vs **9.8%** activos).

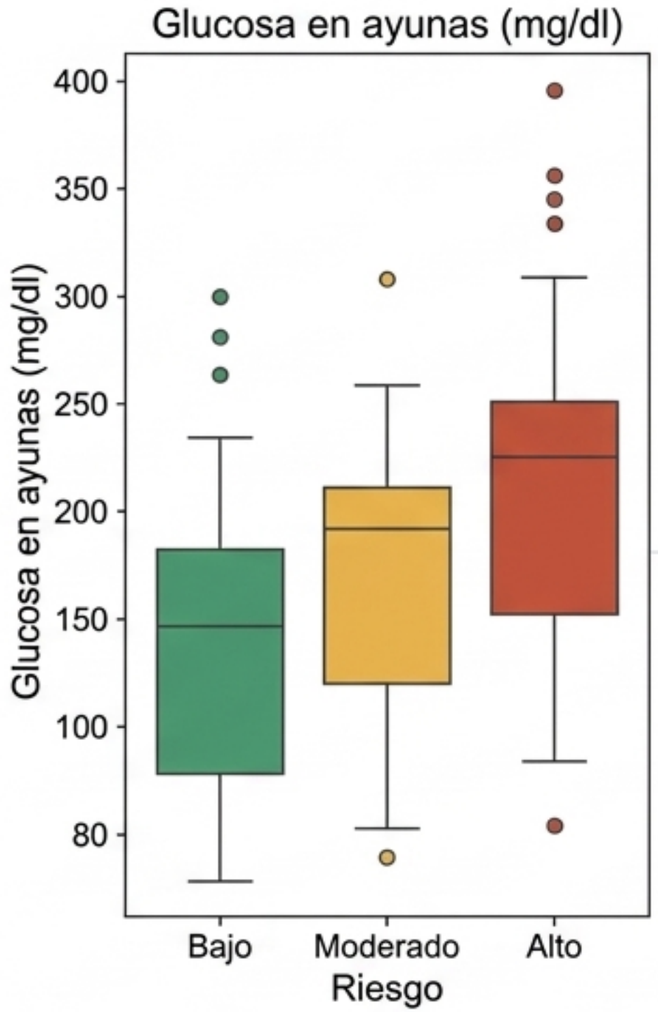
Antecedentes familiares elevan el riesgo al **19.7%** (vs **12.5%** sin ellos).

**Falsos culpables:**

Sexo, dieta, tabaquismo y alcohol **NO** mostraron asociación estadística ($p > 0.3$).

Gemini Notebook

# Glucosa y HbA1c separan casi perfectamente los niveles de riesgo



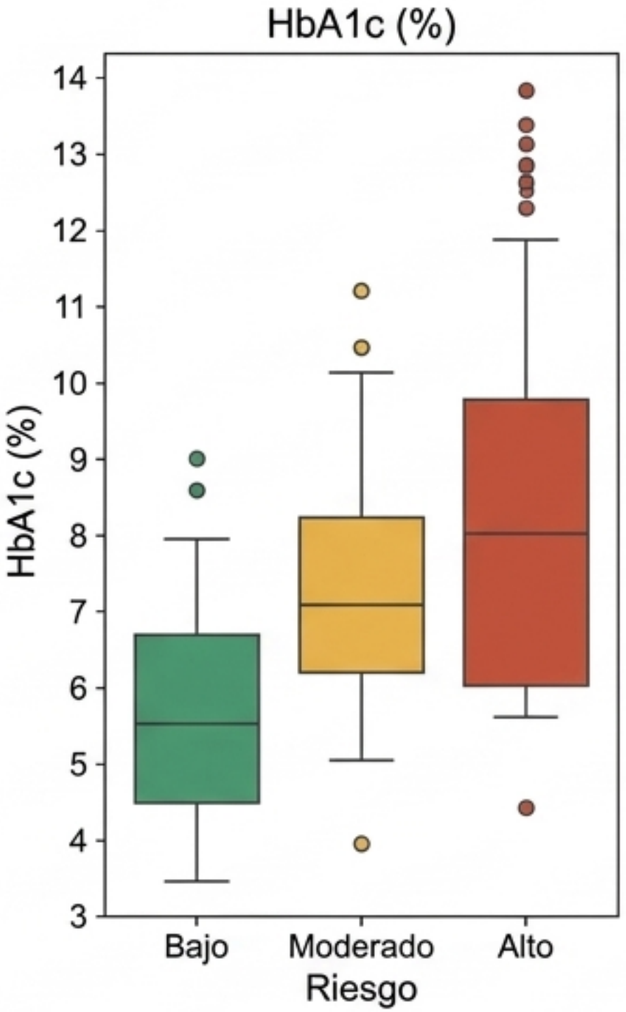

**Glucosa en ayunas**

La media pasa de **148 mg/dl** (Riesgo Bajo) a **226 mg/dl** (Riesgo Alto).

**Insight Clínico-Estadístico**

Correlación de **0.91**

Ambas miden fisiológicamente casi lo mismo, lo que penaliza fuertemente el supuesto de independencia del modelo **Naive Bayes** (color #c8553d).




**HbA1c**

La media se eleva de **6.4%** (Riesgo Bajo) a **8.1%** (Riesgo Alto).

Gemini Notebook

# Sin indicadores metabólicos, el desempeño de todos los modelos colapsa

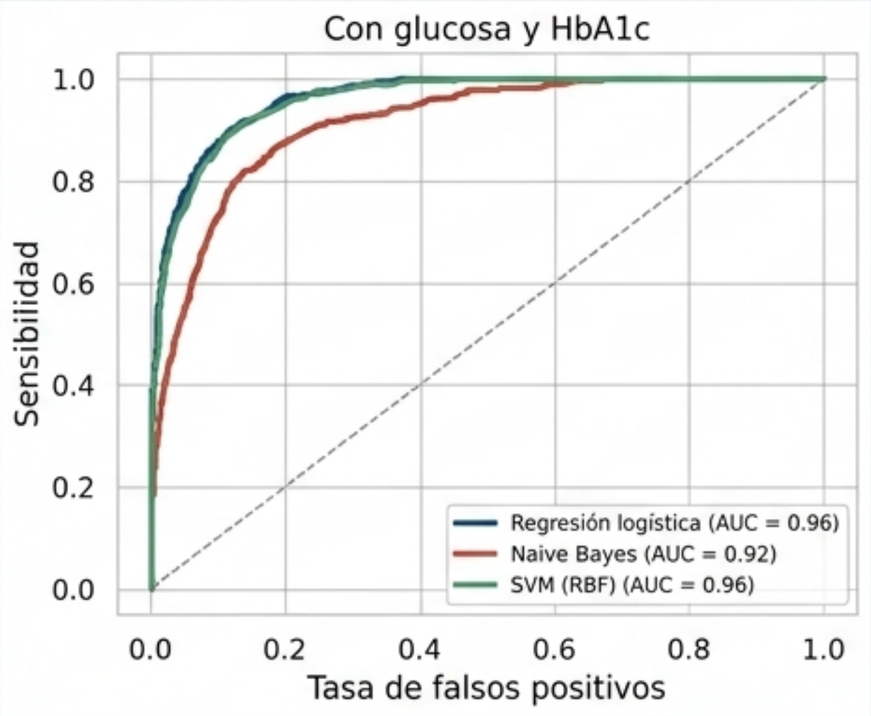
| | Regresión Logística | Naive Bayes | SVM (RBF) |
|---|---|---|---|
| **Escenario 1:** Con Glucosa y HbA1c | AUC: **0.91**<br>Exactitud: **0.76** (Líder) | AUC: **0.87**<br>Exactitud: **0.72** | AUC: **0.91**<br>Exactitud: **0.75** |
| **Escenario 2:** Sin Glucosa ni HbA1c | AUC: **0.69**<br>Exactitud: **0.52** | AUC: **0.65**<br>Exactitud: **0.53** | AUC: **0.69**<br>Exactitud: **0.53** |

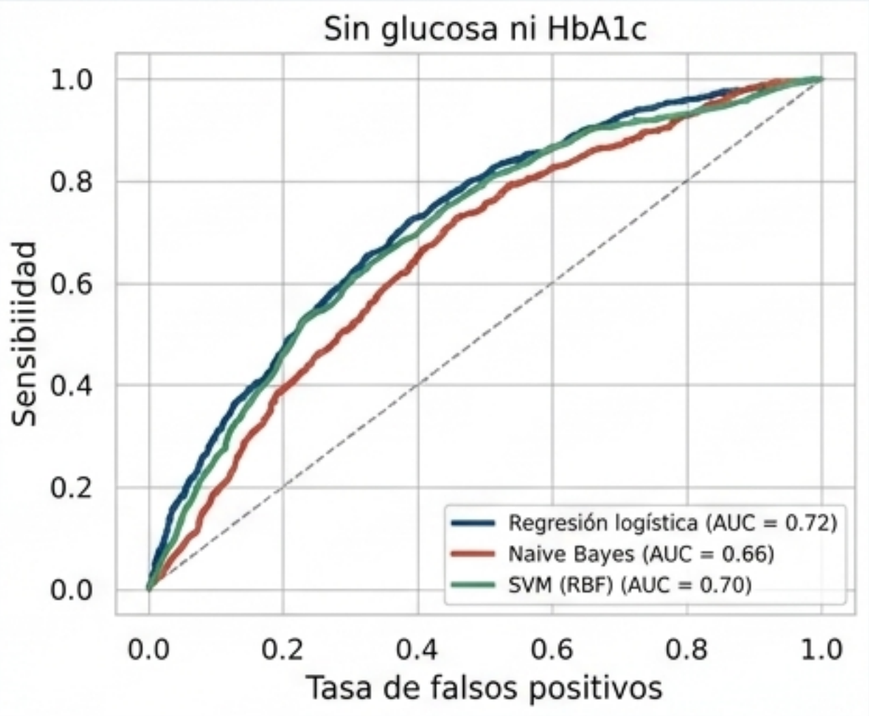
**CAÍDA LIBRE**

Sin las dos métricas de laboratorio, el modelo predice apenas mejor que el azar.

Gemini Notebook

# Las variables de estilo de vida por sí solas no sirven como herramienta de detección




### Con variables clínicas

- **AUC alcanza 0.96 (LogReg/SVM)** aislando el Riesgo Alto.
- **Alta** sensibilidad (0.88) con precisión aceptable (0.59).

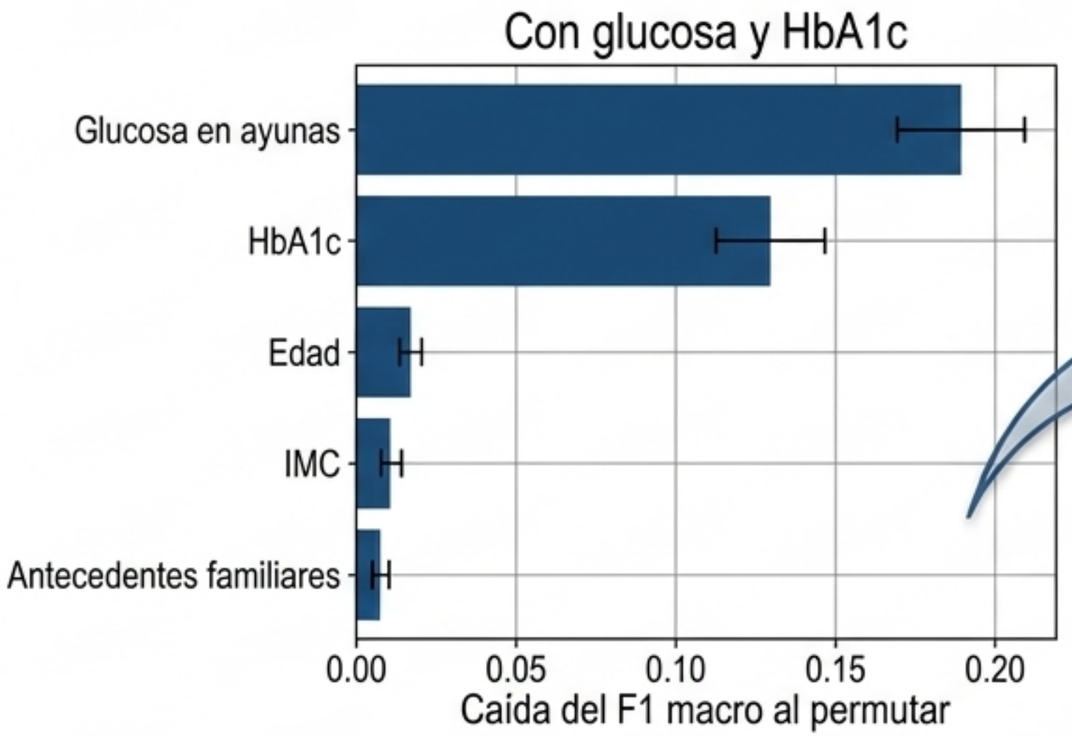
### Sin variables clínicas

- El **AUC general cae a 0.72**.
- El problema real: **La precisión se desploma al 26%**.
- **Insight:** Sin glucosa ni HbA1c, **3 de cada 4 alertas de alto riesgo son falsas positivas**.

Gemini Notebook

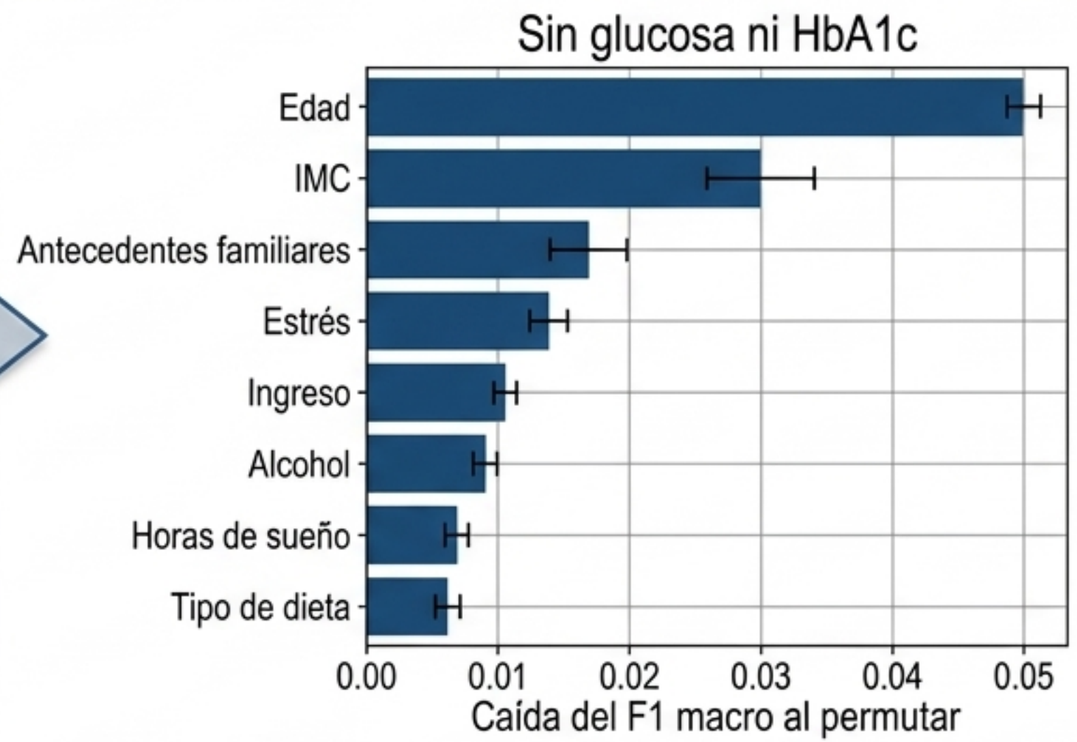
# El desplazamiento de la importancia: De marcadores biológicos a demográficos

## Escenario Base: Con Variables Clínicas




El riesgo está monopolizado por Glucosa (caída F1: 0.19) y HbA1c (0.13). Todo lo demás es estadísticamente residual.

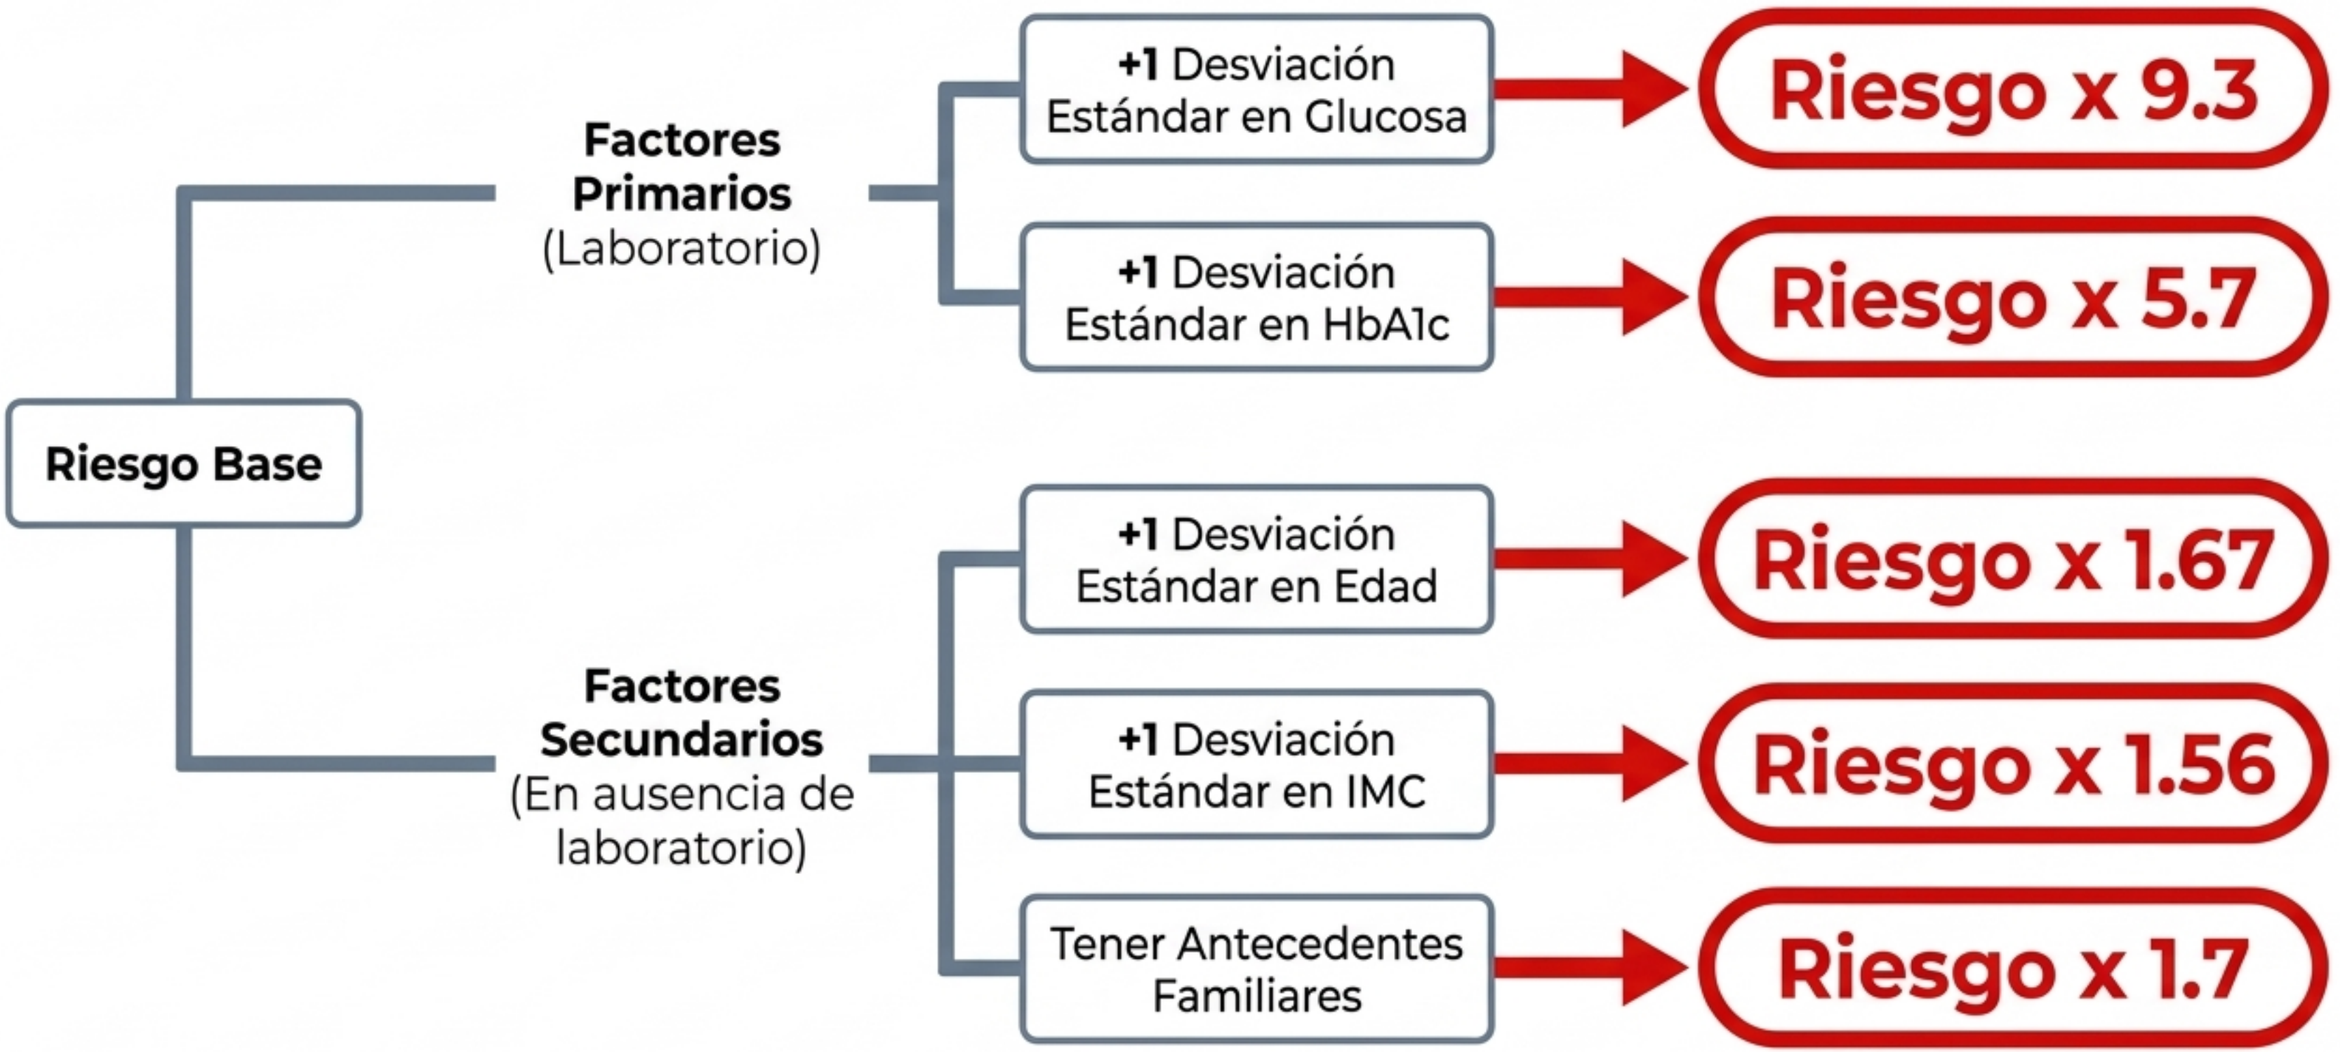
## Escenario Restringido: Sin Glucosa/HbA1c




La carga predictiva se transfiere totalmente a características demográficas y físicas: Edad (0.05), IMC (0.03) y Antecedentes (0.02).

Gemini Notebook

# Explicabilidad del modelo: **Multiplicadores del Riesgo Alto (LogReg)**




*Multiplicadores basados en coeficientes de la Regresión Logística Binaria.

Gemini Notebook

# K-Means identifica 4 perfiles clínicos subyacentes alineados con el riesgo

### Perfil 1: Jóvenes sin alteraciones



**29.1% de la población**

- 91.5% riesgo bajo.
- Glucosa y presión óptimas.



### Perfil 2: Mayores con presión elevada



**32.2% de la población**

- Metabólicamente promedio.
- Hipertensos (sistólica 144).
- Principalmente riesgo bajo/mod.



### Perfil 3: Glucemia alta



**14.9% de la población**

- Concentran el peligro.
- Glucosa 228, HbA1c 8.2.
- 62.3% son de riesgo alto.



### Perfil 4: Obesidad abdominal



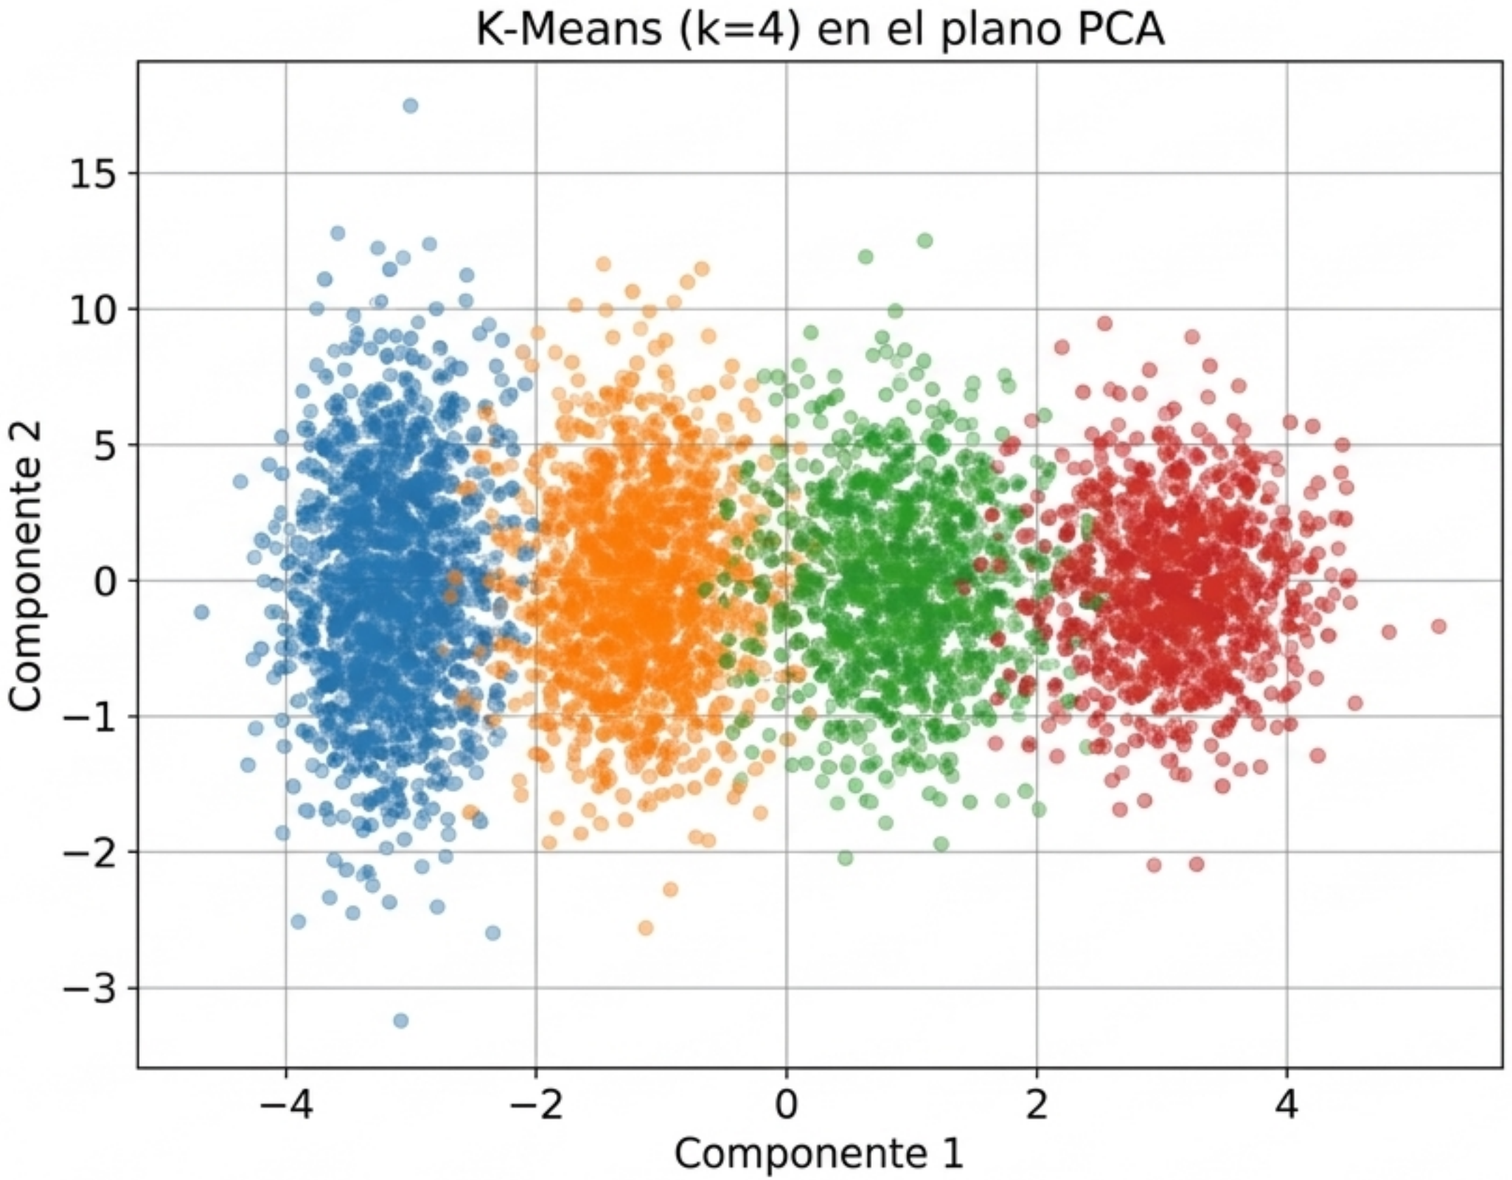
**23.7% de la población**

- IMC (28.3) y cintura (114 cm) muy altos.
- 62% son sedentarios.
- Riesgo altamente fragmentado.



Gemini Notebook

# Los perfiles clínicos forman un continuo, no grupos aislados




## Análisis Visual

Los dos primeros componentes principales explican el 70.5% de la varianza total de los datos.

## Contexto Técnico

**Métrica Silhouette Score: 0.195**

**¿Qué significa?**

Las fronteras entre los perfiles son suaves y se traslapan. K-Means revela “tendencias clínicas” graduales, no fronteras diagnósticas matemáticamente cerradas.

Gemini Notebook

# Discusión: ¿Capacidad predictiva real o artefacto de los datos sintéticos?

## El Hallazgo Matemático

La **Regresión Logística** demuestra **superioridad absoluta** al lograr el mejor equilibrio entre un **altísimo desempeño (AUC 0.91)** e **interpretabilidad transparente** de los coeficientes.

Vs

## La Advertencia Clínica ⚠

En este dataset sintético, el **87% de los pacientes ya superaba los criterios clínicos reales de diabetes (glucosa > 126 mg/dl)**.

## Implicación Crítica

Es altamente probable que la etiqueta objetivo fuera **pre-calculada** a partir de la **Glucosa/HbA1c**. El desempeño "casi perfecto" de los modelos con estas variables es lógicamente **optimista** y **no refleja una verdadera inferencia temprana, sino una confirmación tautológica.**

Gemini Notebook

# Conclusiones del Análisis

1

## Variables Determinantes

El riesgo de diabetes en esta población se define de manera casi exclusiva por los niveles de **Glucosa y HbA1c.** Su poder predictivo **eclipsa** matemática y clínicamente a cualquier otro factor.

2

## Marcadores Secundarios

En escenarios donde no se disponga de pruebas de laboratorio, la vigilancia combinada de **Edad**, **IMC** y **Antecedentes Familiares** ofrece la mejor (aunque limitada) señal predictiva disponible.

3

## Recomendación Algorítmica

Para tareas de clasificación de riesgo clínico, la **Regresión Logística Multinomial** proporciona el modelo óptimo. Iguala a la **SVM** en potencia, supera a **Naive Bayes**, y ofrece la interpretabilidad necesaria para decisiones médicas.

Gemini Notebook