Factores demográficos, de estilo de vida y clínicos asociados a la diabetes en población adulta: un enfoque de clasificación con minería de datos

Yago Raúl Huerta Orozco
Diplomado de Minería de Datos y Técnicas Estadísticas, Módulo 3 · FES Acatlán, UNAM

Resumen

La diabetes es una de las enfermedades crónico-degenerativas más frecuentes y una causa importante de complicaciones graves. Este trabajo busca describir la distribución del nivel de riesgo de diabetes (bajo, moderado y alto) en un conjunto de 15,000 registros de adultos y determinar qué factores demográficos, de estilo de vida y clínicos se asocian con un mayor riesgo. Se emplea el conjunto sintético *Diabetes Risk Prediction* (18 variables predictoras y una de respuesta). Tras una exploración y un preprocesamiento de los datos, se plantea ajustar modelos de clasificación (regresión logística multinomial, Naive Bayes y máquinas de soporte vectorial) con una división entrenamiento/prueba de 70/30, y evaluarlos con matriz de confusión, precisión, sensibilidad (*recall*), curvas ROC y área bajo la curva (AUC), además de la importancia de las variables. Al ser datos observacionales y sintéticos, los resultados se interpretarán como asociaciones con fines académicos y no como relaciones causales.

Palabras clave: diabetes, factores de riesgo, minería de datos, clasificación, regresión logística.

1. Introducción

La diabetes es una enfermedad crónica que afecta a una proporción creciente de la población. De acuerdo con la Organización Mundial de la Salud (OMS), el número de personas con diabetes pasó de 200 millones en 1990 a 830 millones en 2022, y más de la mitad de ellas no recibía medicación para tratarla (World Health Organization [WHO], 2024). La enfermedad puede provocar infarto, enfermedad renal, pérdida de la visión y amputaciones, por lo que su detección oportuna tiene un alto valor para la salud pública. La misma fuente señala que, en la diabetes tipo 2, el sobrepeso, la falta de actividad física, la edad y los antecedentes familiares incrementan el riesgo (WHO, 2024). Conocer qué características de las personas se relacionan con la enfermedad permite dimensionar el problema y reconocer qué hábitos y condiciones conviene vigilar o modificar a tiempo.

Desde la minería de datos, este es un problema de clasificación supervisada: a partir de las características observadas de una persona se busca predecir su nivel de riesgo de diabetes, y a la vez identificar qué variables aportan más a esa distinción (Géron, 2019; James et al., 2013). Modelos como la regresión logística ofrecen coeficientes interpretables en términos de razones de momios, mientras que otros métodos, como Naive Bayes o las máquinas de soporte vectorial (SVM), permiten contrastar el desempeño con supuestos distintos.

El presente proyecto plantea la siguiente pregunta de investigación: ¿cómo se distribuye el riesgo de diabetes en la población adulta del conjunto de datos y qué factores demográficos, de estilo de vida y clínicos se asocian con que una persona tenga un riesgo mayor? En particular, se examina si la edad, el sexo, la ciudad de residencia, el índice de masa corporal (IMC) y los hábitos de vida, incluida la actividad física si la base la contempla, diferencian a las personas de riesgo alto de las de riesgo bajo. El objetivo general es obtener un perfil descriptivo de la población, identificar las variables con asociación clara con la enfermedad y comparar al menos dos técnicas de clasificación vistas en el módulo en cuanto a su capacidad predictiva e interpretabilidad. Dado que los datos son observacionales, se hablará de factores asociados y no de causas comprobadas.

2. Materiales y métodos

2.1 Materiales. Se utiliza el conjunto *Diabetes Risk Prediction* (Aggarwal, s. f.), publicado en Kaggle, en su archivo `diabetes_risk.csv` (1.54 MB). Contiene 15,000 registros y 19 columnas: un identificador por paciente, 17 predictoras y la variable de respuesta, por lo que supera el mínimo requerido de 400 registros y 10 variables. Hay ocho variables predictoras categóricas: sexo (51 % hombres, 48 % mujeres y 1 % otro), ciudad de residencia en la India (18 ciudades; Mumbai 15 % y Delhi 12 %), antecedentes familiares de diabetes (35 % sí), nivel de actividad física (activo, moderado y sedentario, cada uno cerca de un tercio), tipo de dieta, tabaquismo, consumo de alcohol y nivel de ingreso. Las numéricas son la edad (18 a 80 años, media de 44.3), el IMC (15.0 a 40.8, media de 23.1), horas de sueño, nivel de estrés (escala de 1 a 10), glucosa en ayunas (72 a 400 mg/dl), hemoglobina glucosilada (HbA1c, 4.8 a 13.4 %), presión arterial sistólica y diastólica, y circunferencia de cintura. La variable de respuesta, `diabetes_risk`, es categórica ordinal con tres niveles: riesgo bajo (60 %), moderado (25 %) y alto (15 %). Tres variables presentan valores faltantes: alcohol (25.3 %), tabaquismo (3.1 %) e ingreso (3.1 %). Los datos son de carácter sintético, de modo que las conclusiones tienen un propósito académico y no clínico. El análisis se realizará en Python con las bibliotecas pandas, seaborn y scikit-learn (Pedregosa et al., 2011).

2.2 Métodos. El análisis se organiza en cuatro etapas. (1) *Exploración y preprocesamiento:* revisión de atípicos y del balance de clases; se descartará el identificador del paciente, se tratarán los faltantes como una categoría «sin dato» (su proporción es similar en los tres niveles de riesgo), se codificarán las variables categóricas (*one-hot*) y se escalarán las numéricas. (2) *Análisis descriptivo:* cálculo de la distribución del nivel de riesgo, general y por grupos de edad, sexo, ciudad, rangos de IMC y actividad física, apoyado en gráficas y en pruebas de asociación. (3) *Modelado:* se dividirán los datos en 70 % para entrenamiento y 30 % para prueba, de forma estratificada y con semilla fija, y se ajustarán una regresión logística multinomial y, como mínimo, otro modelo de los vistos en el módulo (Naive Bayes o SVM). Como la clase de riesgo alto es minoritaria (15 %), se ponderarán las clases y se complementará el análisis con una versión binaria (riesgo alto frente al resto). Dado que la glucosa en ayunas y la HbA1c son indicadores clínicos muy ligados al riesgo y podrían estar cerca de definir la etiqueta en datos sintéticos, se compararán los modelos con y sin esas dos variables para distinguir su aporte del de los hábitos y rasgos demográficos. El escalado y el ajuste se harán solo con el conjunto de entrenamiento para evitar fuga de información. (4) *Evaluación:* se compararán los modelos con matriz de confusión, precisión, sensibilidad, curvas ROC y AUC (uno contra el resto) en el conjunto de prueba, y se medirá la importancia de las variables mediante los coeficientes de la regresión logística y la importancia por permutación. Los modelos elegidos podrán ajustarse conforme avance el curso.

Referencias

Aggarwal, M. (s. f.). *Diabetes risk prediction* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/mansiaggarwal88/diabetes-risk-prediction

Géron, A. (2019). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (2.ª ed.). O'Reilly Media.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An introduction to statistical learning: With applications in R*. Springer.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830.

World Health Organization. (2024, 14 de noviembre). *Diabetes* [Hoja informativa]. https://www.who.int/news-room/fact-sheets/detail/diabetes