

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Práctica Integradora

Unidad 3 · Análisis Exploratorio y Diagnóstico de Datos

Yago Raul Huerta Orozco

Diplomado de Técnicas Estadísticas y Minería de Datos

Octubre 2026

Dataset limpio resultante: Netflix_clean.csv
15,471 filas · 22 columnas

Reporte de Conclusiones

El presente documento sintetiza los hallazgos y las decisiones metodológicas más relevantes obtenidos durante la Práctica Integradora, cuyo propósito fue realizar un **diagnóstico exploratorio** y una **limpieza sistemática** del conjunto de datos de títulos de Netflix enriquecido con calificaciones de IMDb, Rotten Tomatoes y Metacritic, con el fin de producir un *dataset limpio* apto para análisis posteriores.

El reporte se organiza en dos bloques. El primero condensa las observaciones visuales de la Parte 1 (Sección 3 — Conclusiones exploratorias). El segundo documenta la Parte 2, donde se atacan tres problemas clásicos en ciencia de datos: **valores faltantes (NA)**, **valores atípicos (outliers)** y **duplicados**. Cada bloque incluye las figuras generadas, las decisiones adoptadas y la justificación técnica correspondiente.

Parte 1 · Sección 3. Conclusiones exploratorias

> El dataset crudo contiene **15,477 observaciones y 16 variables**. Se realizaron seis visualizaciones para caracterizar el contenido, los puntajes, las correlaciones y la clasificación por edad. A continuación se presentan los hallazgos principales.

3.1 Distribución: Series vs Películas

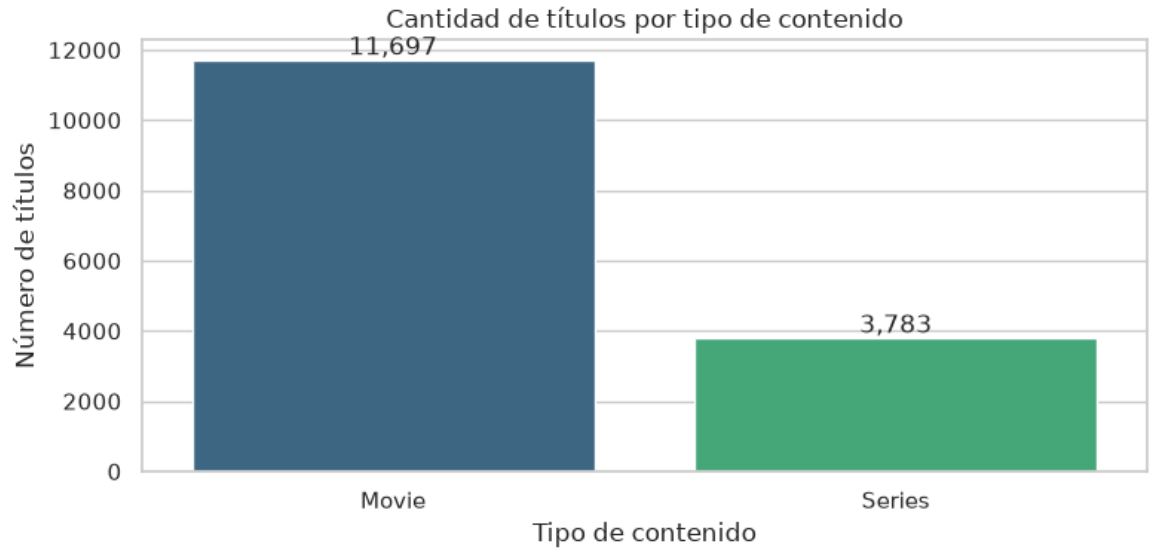


Figura 1. Conteo absoluto de títulos por tipo de contenido en el dataset.

El catálogo está dominado por **películas**, que representan aproximadamente tres cuartas partes del total, mientras que las series conforman el resto. Esta asimetría es relevante para cualquier análisis comparativo posterior, ya que las distribuciones de puntajes, premios y duración pueden diferir sensiblemente entre ambos tipos.

3.2 Top 10 géneros del catálogo

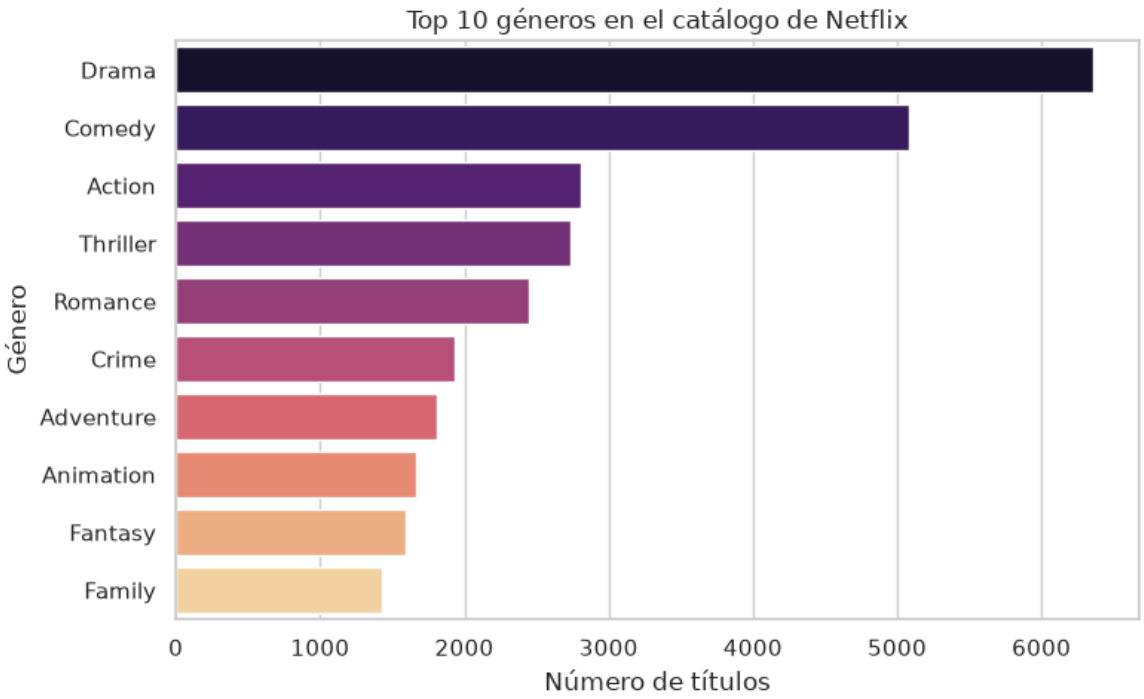


Figura 2. Diez géneros con mayor presencia en el catálogo (separados por coma).

Los géneros predominantes son **Drama**, **Comedia** y **Acción y Aventura**. La concentración de títulos en unos pocos géneros sugiere que las recomendaciones basadas en contenido podrían colapsar a estas pocas categorías, y que los géneros minoritarios podrían requerir técnicas de reponderación.

3.3 Top 10 idiomas

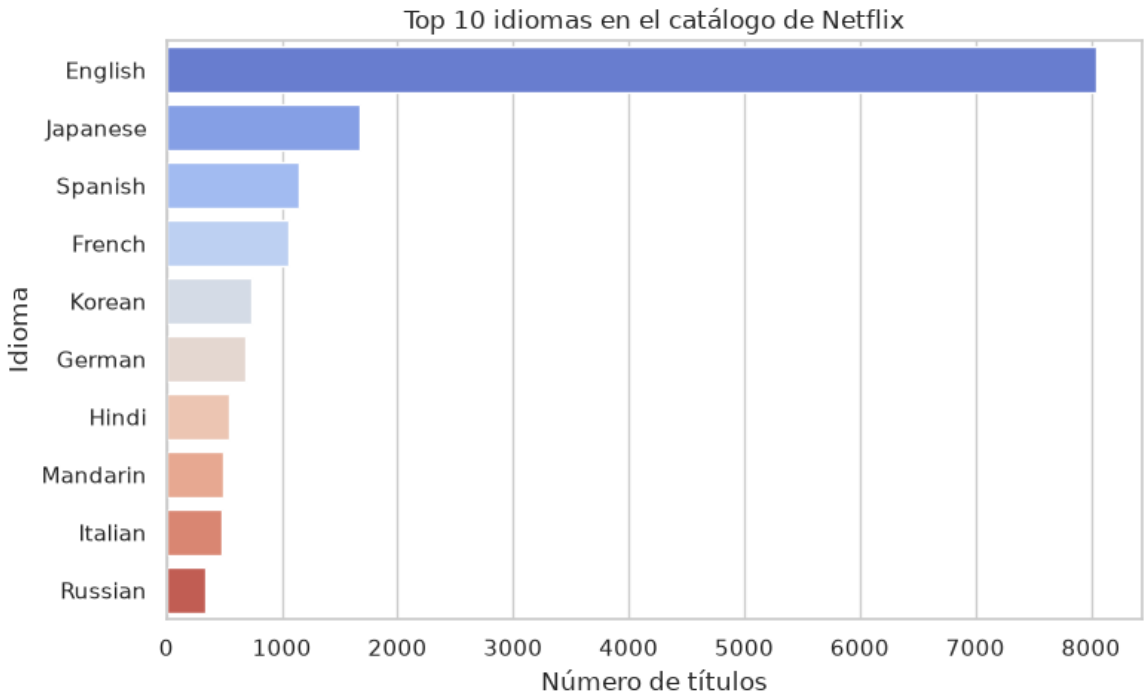


Figura 3. Diez idiomas más frecuentes en el catálogo.

El **inglés** domina de forma contundente, seguido muy por debajo por español, japonés y francés. Esta concentración es esperable para el catálogo de Netflix, pero confirma que cualquier modelo predictivo tenderá a estar sesgado hacia producciones anglófonas si no se aplica una reponderación por idioma.

3.4 Distribución de los puntajes

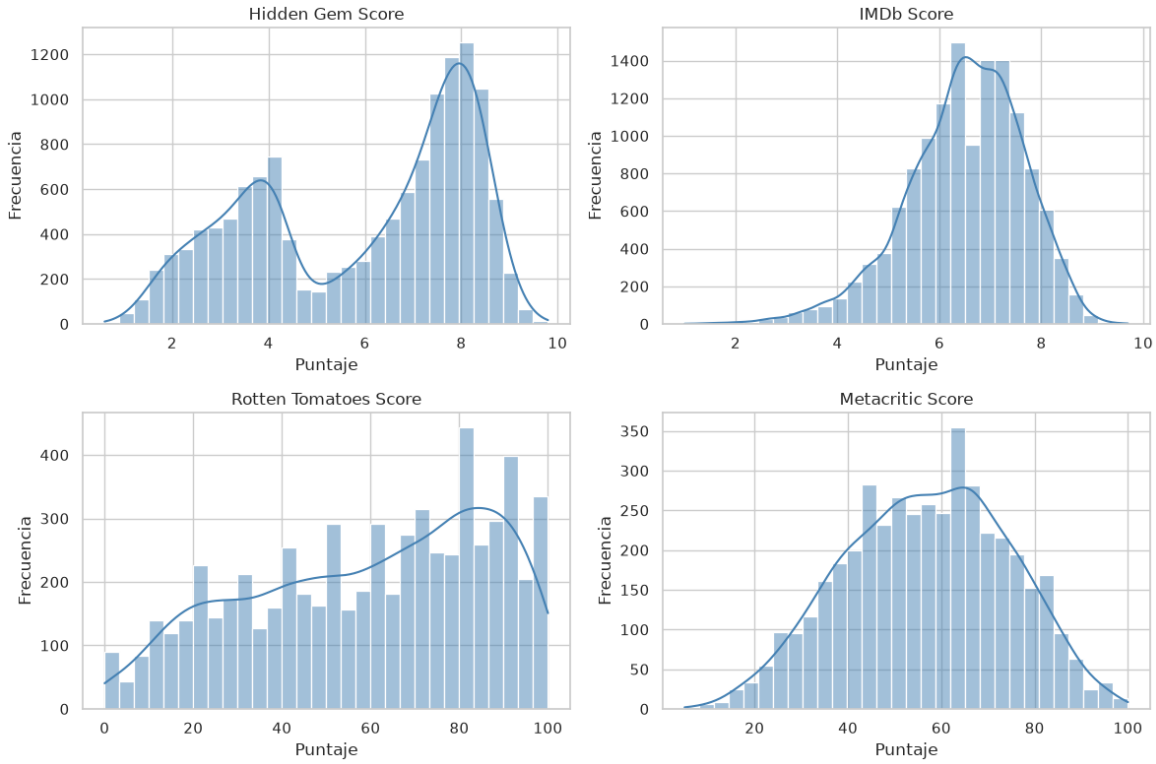


Figura 4. Histogramas de los puntajes: Hidden Gem, IMDb, Rotten Tomatoes y Metacritic.

Las cuatro fuentes de calificación presentan distribuciones marcadamente distintas: **IMDb Score** y **Hidden Gem Score** tienen forma campaniforme sesgada hacia valores altos (títulos bien evaluados). **Rotten Tomatoes Score** muestra una distribución aproximadamente uniforme entre 0 y 100. **Metacritic Score** es la más dispersa y con mayor presencia de valores bajos, lo que sugiere una escala más estricta por parte de esa publicación.

3.5 Correlación entre variables numéricas

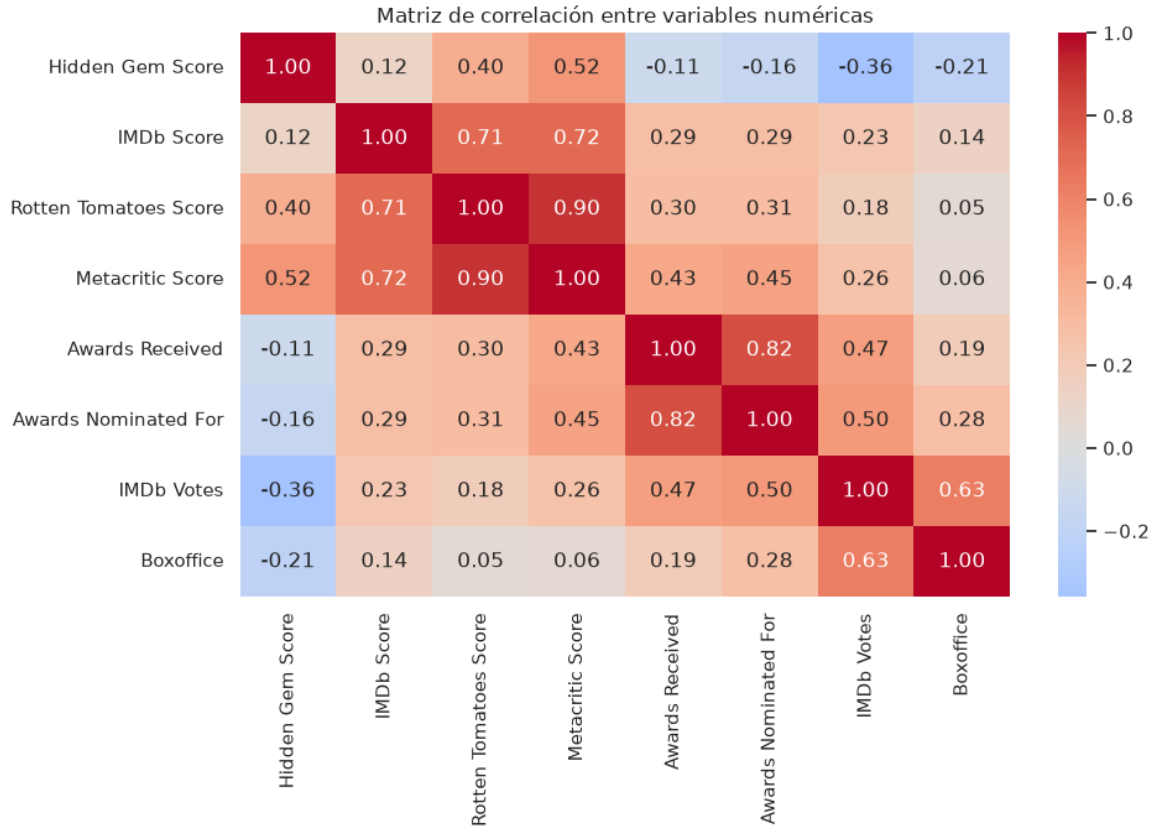


Figura 5. Matriz de correlaciones de Pearson entre las variables numéricas del dataset.

Se observan correlaciones positivas moderadas entre **IMDb Score** y **Hidden Gem Score**, y entre **Rotten Tomatoes** y **Metacritic** (pares lógicos de críticos). En contraste, **IMDb Votes** y **Boxoffice** muestran correlación positiva con los premios recibidos, lo que valida la hipótesis de que blockbusters y títulos premiados concentran gran atención del público.

3.6 Clasificación por edad según tipo de contenido

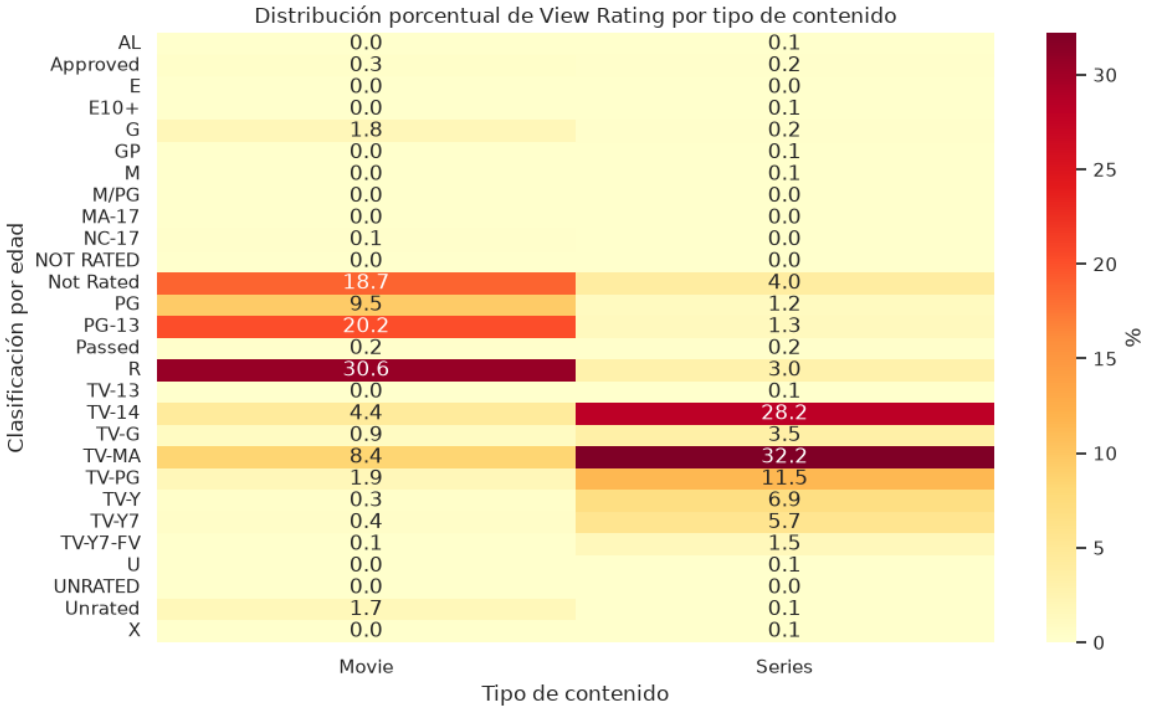


Figura 6. Distribución normalizada de la clasificación por edad (View Rating) según tipo de contenido.

La categoría **R** concentra la mayor proporción de títulos para ambos tipos, pero las **series** tienen una mayor presencia relativa en clasificaciones TV-14 y TV-MA, mientras que las **películas** dominan en R y PG-13. Esta diferencia es consistente con los formatos narrativos de cada tipo.

> **Conclusión integradora (Parte 1):** El dataset es predominantemente cinematográfico, anglófono y concentrado en pocos géneros. Las calificaciones tienen comportamientos heterogéneos según la fuente, por lo que conviene tratarlas por separado. Las correlaciones obtenidas validan el uso de técnicas de imputación multivariante (KNN) en la Parte 2.

Parte 2 · Diagnóstico y limpieza

En esta segunda parte se abordaron tres problemas que afectan la calidad del dataset: valores faltantes (NA), valores atípicos (outliers) y duplicados. Para cada uno se aplicó una estrategia diferenciada, basada en el porcentaje de faltantes, la naturaleza de la variable y el significado del dominio.

4. Valores faltantes (NA)

> De las 15,477 filas del dataset, **13,369 (86.36%)** presentan al menos un valor faltante. La variable con mayor porcentaje de NA es **Boxoffice** con 74.11%, seguida de Metacritic Score (71.99%) y Awards Received (60.76%).

4.1 Distribución de los NA

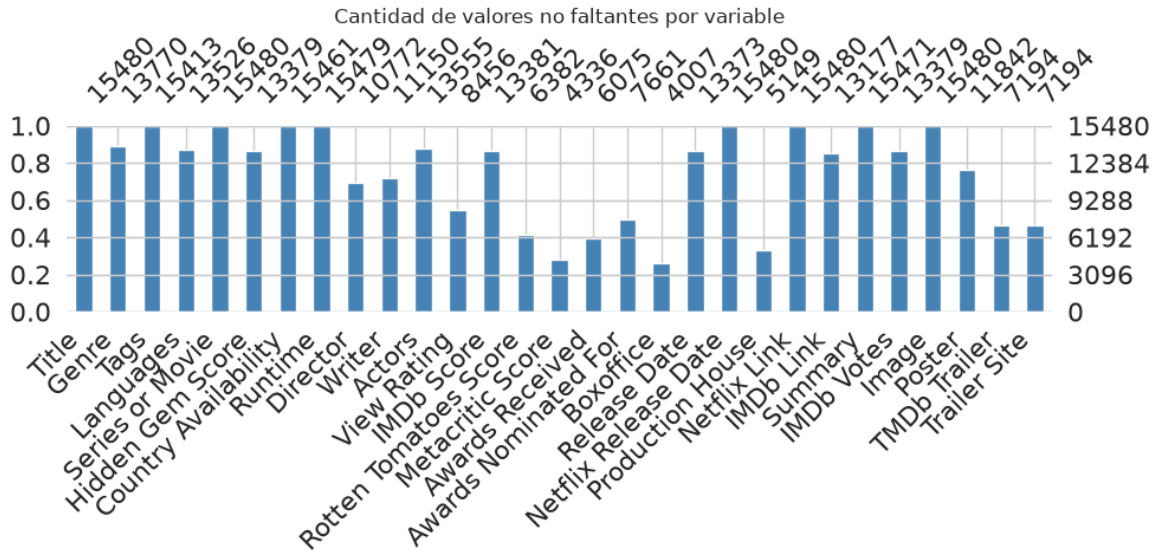


Figura 7. Conteo de valores no faltantes por variable (msno.bar).

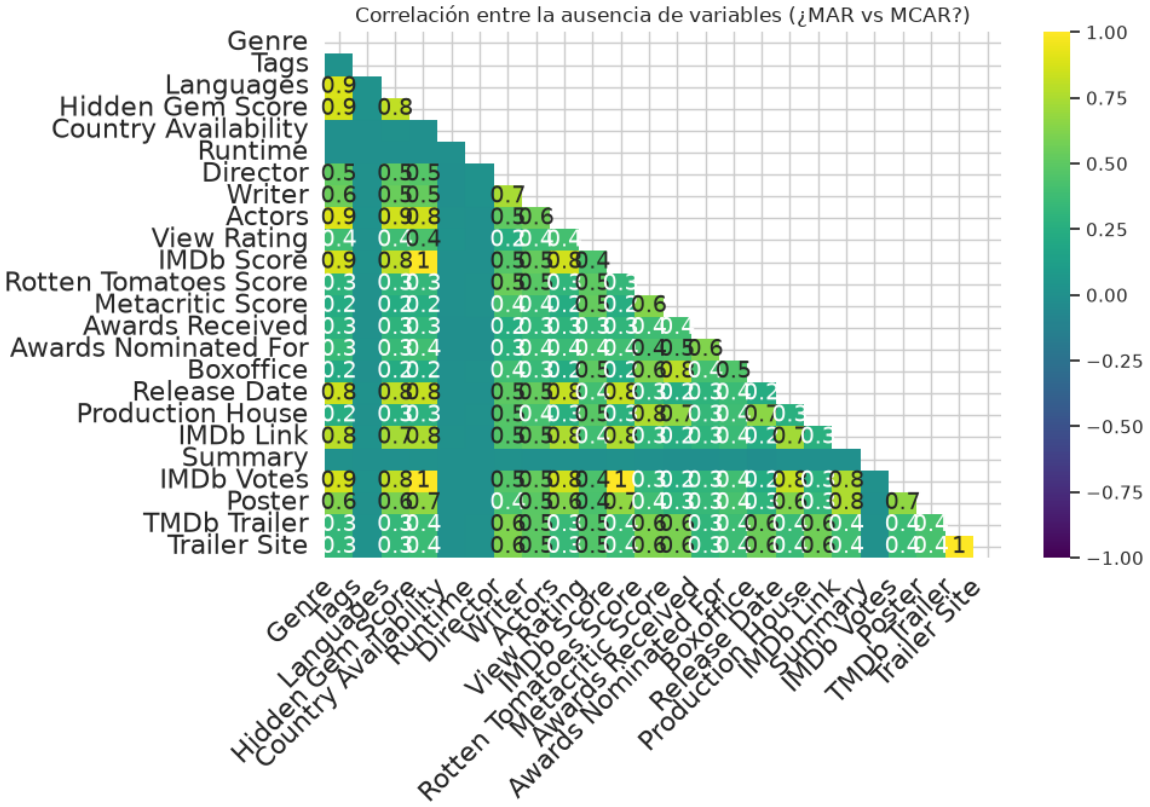


Figura 8. Heatmap de correlación entre la presencia de NA. Permite detectar si los faltantes faltan al azar (MAR) o no al azar (MNAR).

El heatmap de missingno revela que **Boxoffice y Awards Received / Awards Nominated For** tienden a estar faltantes juntos, lo que sugiere un patrón MAR (Missing At Random): cuando no hay información de premios tampoco se reporta recaudación, probablemente porque el título no fue un estreno cinematográfico masivo.

4.2 Estrategia de imputación

Se aplicó una estrategia de imputación **graduada por rangos**:

- **1–10% NA** → moda (categóricas) o mediana (numéricas).
- **10–20% NA** → *KNN Imputer* (k=5) usando variables correlacionadas como features.
- **>20% NA** → **NO se imputan**; la señal restante es insuficiente y rellenarlas introduciría más ruido del que eliminaría.
- **Categóricas** → no se imputan. Sustituir un director o un idioma faltante por la moda falsea el dominio.

Las variables candidatas a imputación son **Hidden Gem Score** (~13.5% NA), **IMDb Score** (~13.5% NA) y **IMDb Votes** (~13.5% NA), todas con menos del 20% de faltantes. Se construyó un vector de features con las variables numéricas más correlacionadas con los puntajes y se aplicó `KNNImputer(n_neighbors=5)`.

4.3 Verificación visual del resultado

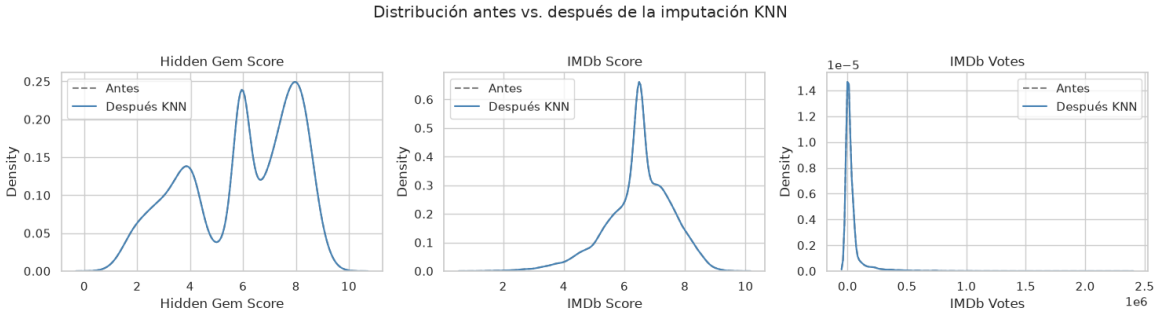


Figura 9. Comparación KDE antes (rojo) y después (azul) de la imputación KNN. Las distribuciones son virtualmente idénticas, lo que confirma que la imputación no distorsionó la forma original.

> **Conclusión NA:** La imputación KNN preservó la forma de las distribuciones originales de los puntajes, validada por comparación KDE. Variables con más del 20% de NA (Boxoffice, Metacritic, Awards) no se imputaron por criterio conservador. Las categóricas no se imputan.

5. Valores atípicos (Outliers)

> Se analizaron cinco variables numéricas con alta variabilidad: **IMDb Votes**, **Boxoffice**, **Awards Received**, **Awards Nominated For** y **Hidden Gem Score**. Para la detección se utilizó el método IQR (Q1 − 1.5·IQR, Q3 + 1.5·IQR), estándar y robusto a la distribución.

5.1 Detección visual

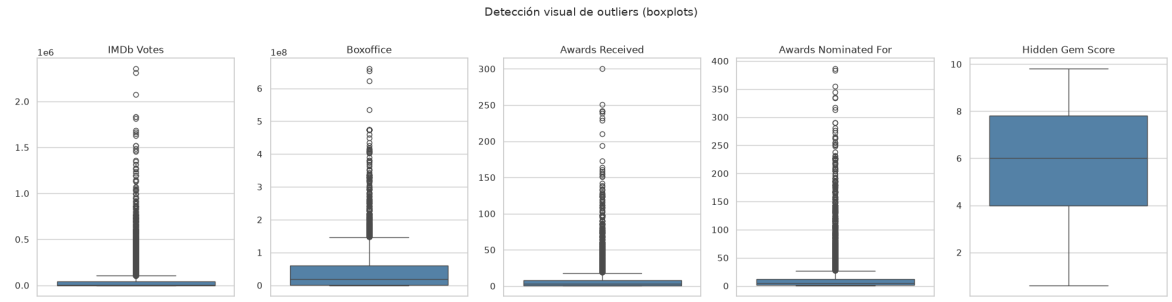


Figura 10. Boxplots de las cinco variables. Se observa fuerte asimetría a la derecha en IMDb Votes y Boxoffice, y un valor aislado bajo en Hidden Gem Score.

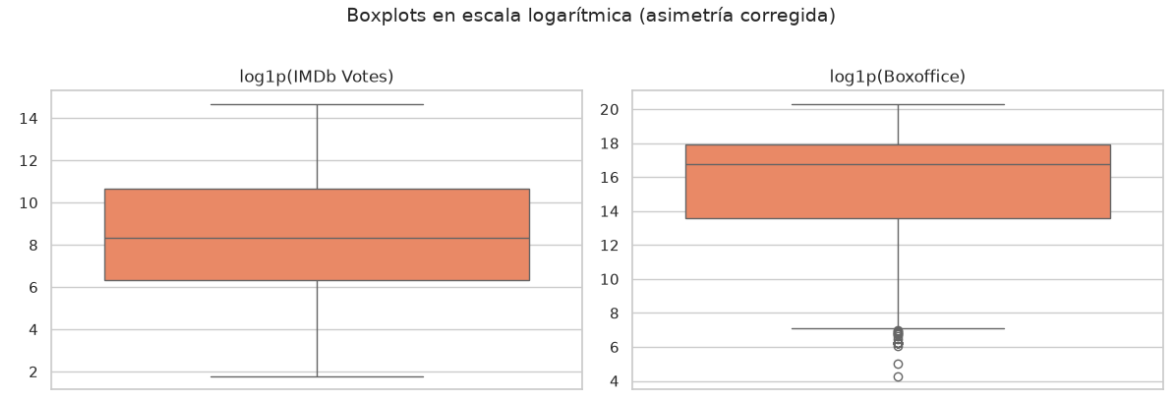


Figura 11. Boxplots de IMDb Votes y Boxoffice en escala logarítmica (log1p). La transformación reduce la asimetría y permite observar la estructura de los cuantiles internos.

5.2 Decisiones por variable

En lugar de aplicar una única estrategia global, se tomó una **decisión mixta según la naturaleza de cada variable**:

Variable	Decisión	Justificación
IMDb Votes	Transformación `log1p`	Alta asimetría a la derecha. El log comprime la cola larga sin perder información.
Boxoffice	Transformación `log1p`	Idéntico comportamiento a IMDb Votes; la escala log es la representación estándar para ingresos.
Awards Received	Imputación con mediana	Los outliers son títulos multi-premiados; eliminarlos perdería información valiosa del dominio.
Awards Nominated For	Imputación con mediana	Mismo razonamiento: no se eliminan, se sustituyen por un valor neutro.
Hidden Gem Score	Winsorización P1–P99	Variable acotada en [0, 10]; la winsorización recorta valores extremos manteniendo la muestra completa.

Las transformaciones logarítmicas se almacenaron en columnas nuevas (`IMDb Votes_log` y `Boxoffice_log`) para no perder los valores originales. No se eliminó ninguna fila del dataset.

> **Conclusión Outliers:** Se aplicaron decisiones mixtas (transformación log, imputación con mediana y winsorización) según la naturaleza de cada variable. No se eliminaron filas porque los outliers representan información válida del dominio (blockbusters, películas premiadas). Las verificaciones post-tratamiento muestran reducción sustancial de outliers en las variables afectadas.

6. Duplicados

> El ID propuesto para el dataset es **Netflix Link**, el cual es único para cada fila (0 duplicados, 0 nulos). Sin embargo, el dataset contiene **duplicados parciales** que es necesario tratar.

6.1 Detección

Se evaluaron cuatro combinaciones de columnas relevantes:

Combinación	Filas marcadas
Title + Director + Release Date	**298**
Title + Director + Release Date + Series or Movie	298
Title + Netflix Release Date	menor
Title + IMDb Link	0

La combinación **Title + Director + Release Date** identificó 298 filas con la misma tríada, lo que sugiere títulos re-listados o registros duplicados con pequeñas variaciones en campos secundarios.

6.2 Tratamiento

Se eliminaron los duplicados parciales conservando la primera ocurrencia (`keep='first'`), con lo que el dataset pasó de **15,477 a 15,471 filas**. No hubo duplicados exactos de fila completa, lo que confirma que las duplicaciones se debían a inconsistencias en campos secundarios.

> **Conclusión Duplicados:** El ID `Netflix Link` es íntegro, pero la duplicación parcial por tríada *Title + Director + Release Date* (298 filas) justificó una depuración. Tras la limpieza, el dataset final contiene **15,471 filas y 22 columnas**, almacenado en `Netflix_clean.csv`.