

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Práctica 3.1: Clasificación

Unidad 3 · Regresión logística, Naive Bayes y SVM

Yago Raul Huerta Orozco

Diplomado de Técnicas Estadísticas y Minería de Datos

Octubre 2026

Dataset: Netflix_clean.csv
15,330 títulos · Objetivo: Series or Movie

Reporte de análisis

1. Planteamiento

El objetivo fue clasificar cada título del catálogo de Netflix como **serie** o **película** (`Series or Movie`; series = clase positiva). La variable es binaria, no tiene faltantes y está desbalanceada (24.4% series), por lo que, además del *accuracy*, se evaluó con precisión, recall, F1 y AUC. Los datos se dividieron en 70% entrenamiento y 30% prueba, de forma estratificada y con semilla fija.

Se usaron **48 predictoras**: `IMDb Score`, `Hidden Gem Score`, votos de IMDb (log), año de llegada a Netflix, número de géneros e idiomas, indicador de inglés, los 12 géneros más frecuentes (multi-hot) y la clasificación por edad (one-hot, con los faltantes como categoría «Desconocido»). Los modelos se entrenaron con variables estandarizadas dentro de un *pipeline* para evitar fuga de información.

> **Decisión clave:** la variable `Runtime` se excluyó del análisis principal porque delata la clase: ninguna serie tiene duración mayor a 30 minutos en esa variable y el 100% de los títulos de 30 min a más de 2 horas son películas. Con ella, el AUC sube a 0.99 y los modelos prácticamente no se distinguen; se reporta solo como análisis de sensibilidad.

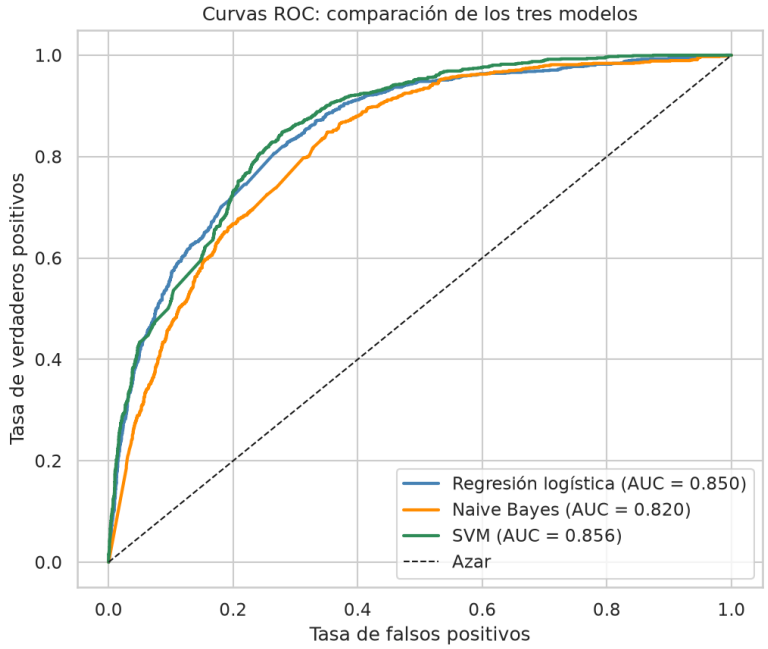
2. Resultados por modelo

- **Regresión logística** (`class_weight="balanced"`): AUC 0.850, recall 0.855 y precisión 0.464. Sin sobreajuste (accuracy 0.729 en entrenamiento vs. 0.724 en prueba). `IMDb Score` multiplica por 1.97 los odds de ser serie por cada desviación estándar; las clasificaciones `R` y `PG-13` empujan hacia película (odds ×0.53 y ×0.56) y `TV-MA`/`TV-14` hacia serie (×1.58 y ×1.53).
- **Naive Bayes** (gaussiano): AUC 0.820, el más bajo. Tiene el mayor recall (0.944; solo se le escapan 63 series), pero clasifica como serie a 1,825 películas, por lo que su precisión es 0.367 y su accuracy 0.589. La independencia y normalidad que supone no se cumplen con variables binarias y relacionadas entre sí.
- **SVM** (kernel RBF, `C=20`, `gamma=0.005` por validación cruzada): AUC 0.856, el más alto; precisión 0.489, recall 0.852 y F1 0.621. Es el que comete menos falsos positivos (999). Su importancia por permutación está liderada por `IMDb Score`.

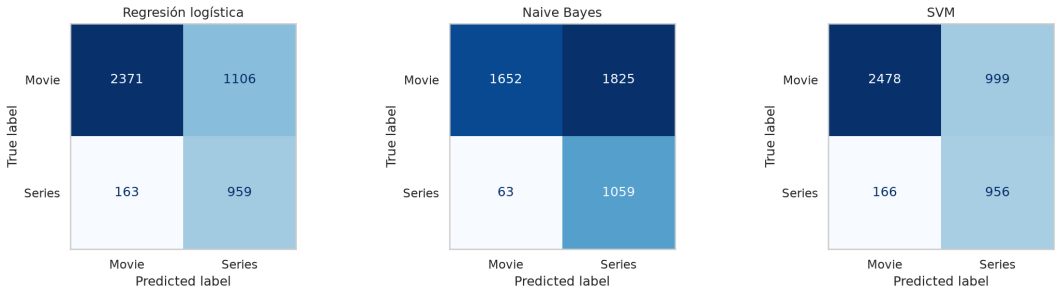
3. Comparación

Modelo	Accuracy	Precisión	Recall	F1	AUC
Regresión logística	0.724	0.464	0.855	0.602	0.850
Naive Bayes	0.589	0.367	**0.944**	0.529	0.820
SVM	**0.747**	**0.489**	0.852	**0.621**	**0.856**

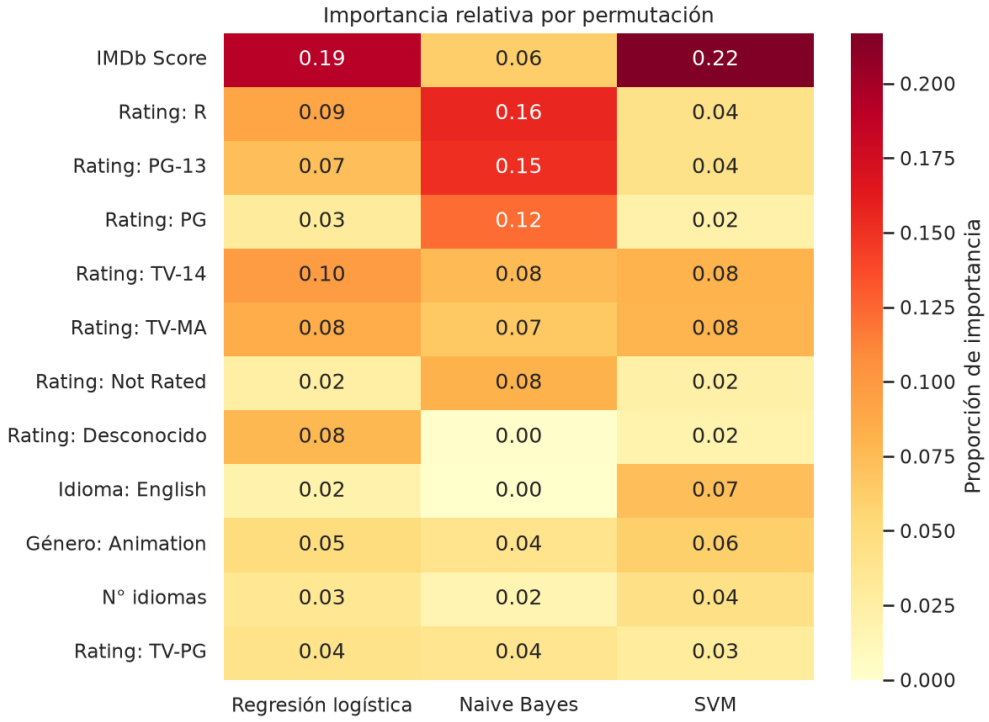
Métricas sobre el conjunto de prueba (n = 4,599). La precisión y el recall corresponden a la clase Series.



Curvas ROC de los tres modelos.



Matrices de confusión en el conjunto de prueba.



Importancia relativa por permutación (cada modelo suma 1).

4. Conclusiones

- El **SVM** es el mejor en accuracy, precisión, F1 y AUC, pero su ventaja sobre la **regresión logística** es mínima (AUC 0.856 vs. 0.850). La regresión logística es mucho más rápida e interpretable, por lo que ofrece la mejor relación desempeño/simplicidad.
- **Naive Bayes** es el más débil. Solo sería preferible si lo prioritario fuera no perder ninguna serie, a costa de muchas falsas alarmas.
- Los tres modelos coinciden en que `IMDb Score` y la clasificación por edad son las señales más informativas: `TV-MA`/`TV-14` se asocian con series y `R`/`PG-13` con películas.
- **Limitación:** la precisión de la clase Series no supera 0.49, es decir, más de la mitad de los títulos predichos como serie son películas. Se debe en parte al desbalance y al umbral por defecto; ajustarlo permitiría equilibrar precisión y recall según la necesidad.
- **Recomendación:** SVM si se busca el máximo desempeño; regresión logística si se prioriza interpretabilidad con un costo mínimo en desempeño.