

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Práctica 3.2: Clasificación

Unidad 3 · Árbol de decisión, Regresión multinomial y CHAID

Yago Raul Huerta Orozco

Diplomado de Técnicas Estadísticas y Minería de Datos

Octubre 2026

Dataset: Netflix_clean.csv
15,330 títulos · Objetivo: Calidad IMDb (Baja / Media / Alta)

Reporte de análisis

1. Planteamiento

La variable objetivo es la calidad del título según IMDb. Se tomó `IMDb Score` y se cortó en terciles: **Baja** (≤ 6.3), **Media** (6.3 a 6.9) y **Alta** (> 6.9). Las clases quedan en 35.7%, 32.0% y 32.3%; un modelo que siempre dijera «Baja» acertaría 35.7%.

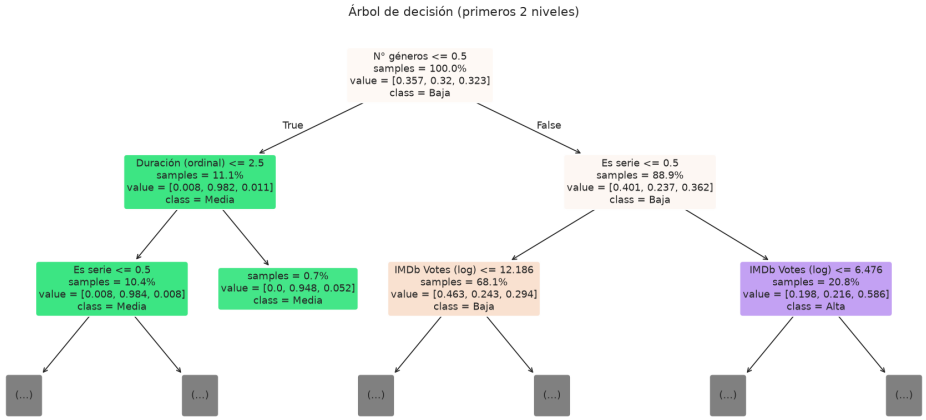
Los datos se dividieron en 70% entrenamiento (10,731 títulos) y 30% prueba (4,599), estratificados por clase. Se usaron 49 predictoras: votos de IMDb (log), años de estreno y de llegada a Netflix, número de géneros e idiomas, duración, serie/película, inglés, los 12 géneros más frecuentes y la clasificación por edad. Para CHAID, las numéricas se pasaron a quintiles. Los hiperparámetros se eligieron con validación cruzada de 5 pliegues sobre entrenamiento, maximizando el AUC macro uno-contra-resto.

> **Fuga de información:** `Hidden Gem Score` se dejó fuera de las predictoras. Junto con los votos llega a AUC 0.93 con un árbol sencillo (los votos solos dan 0.68). Al agregarla al modelo, el AUC del árbol sube de 0.80 a 0.95. `Rotten Tomatoes` y `Metacritic` se descartaron por tener 59% y 72% de faltantes.

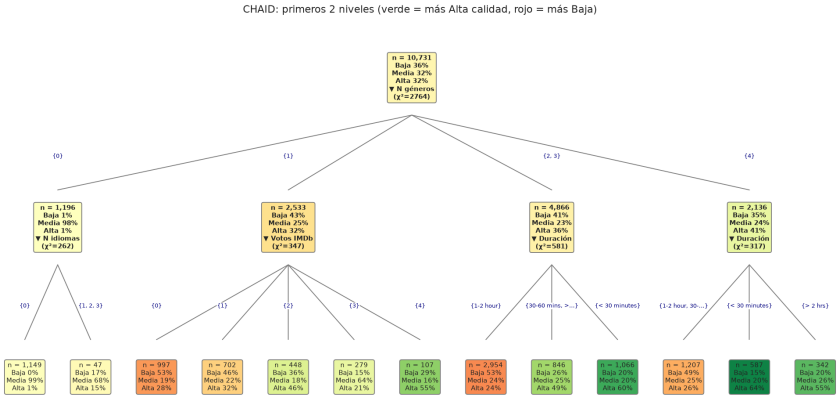
2. Resultados por modelo

- **Árbol de decisión** (profundidad 15, 127 hojas, `min_samples_leaf=60`): accuracy 0.638 y AUC macro 0.800. La raíz separa a los títulos sin géneros (11.1% del entrenamiento), que son 98% Media. Con géneros divide por `Es serie`: las películas (68.1%) son 46% Baja y las series (20.8%) son 59% Alta, y en ambas el siguiente corte son los votos. Las variables que más pesan son los votos, `Es serie` y el número de géneros.
- **Regresión multinomial** (`C=100`): accuracy 0.615 y AUC 0.778. Es la más estable (la brecha de AUC entre entrenamiento y prueba es casi cero) y la que menos errores graves comete (13.7%). Ser serie, tener más géneros y durar más empujan hacia Alta; Thriller y Comedia, hacia Baja.
- **CHAID** (profundidad 7, 140 hojas): accuracy 0.629 y AUC 0.787. La raíz divide por `N géneros` (χ^2 = 2,764). Con 2 o 3 géneros, los títulos de menos de 30 minutos son 60% Alta (n = 1,066) y los de 1 a 2 horas son 53% Baja (n = 2,954). Duración y «Es serie» casi coinciden: 3,739 de las 3,740 series duran menos de 30 minutos.

Los títulos sin géneros (1,708 en total) son casi todos los que tienen la calificación imputada con la mediana: en entrenamiento son 98% Media. El árbol y CHAID los mandan a Media, y por eso su precisión en esa clase es tan alta (0.87 y 0.85).



Árbol de decisión: primeros dos niveles (verde = Media, naranja = Baja, morado = Alta; value = proporciones de [Baja, Media, Alta]).

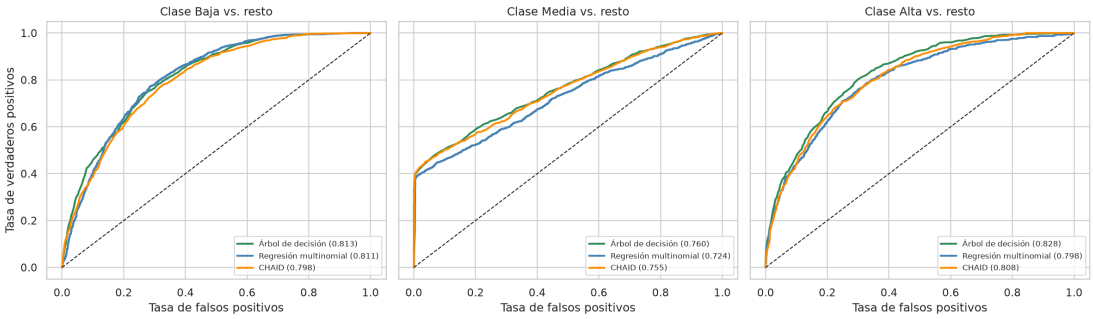


CHAID: primeros dos niveles (verde = más calidad Alta, rojo = más Baja). Votos IMDb en quintiles, de 0 (menos votos) a 4 (más votos).

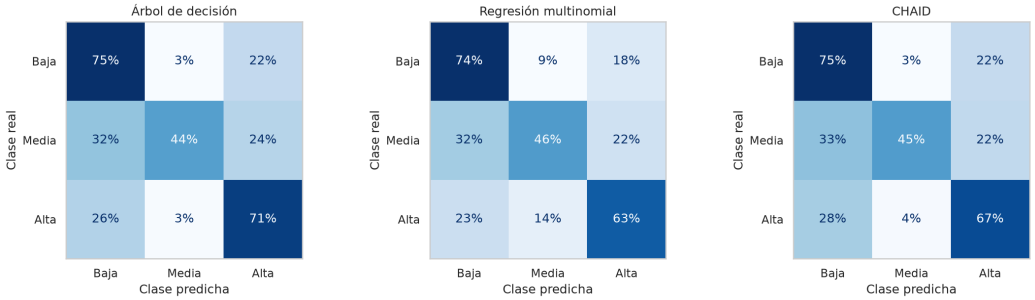
3. Comparación

Modelo	Accuracy	Precisión (macro)	Recall (macro)	F1 (macro)	AUC (macro)
Árbol de decisión	**0.638**	**0.685**	**0.633**	**0.631**	**0.800**
Regresión multinomial	0.615	0.621	0.610	0.607	0.778
CHAID	0.629	0.673	0.624	0.623	0.787

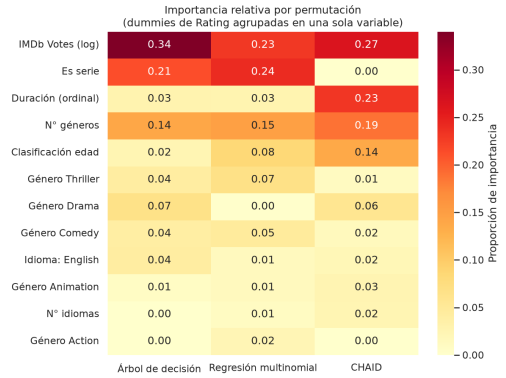
Métricas sobre el conjunto de prueba (n = 4,599). AUC macro uno-contra-resto.



Curvas ROC uno-contra-resto por clase (entre paréntesis, el AUC).



Matrices de confusión normalizadas por fila (conjunto de prueba).



Importancia relativa por permutación (cada modelo suma 1; las dummies de clasificación por edad se agrupan).

4. Conclusiones

- El **árbol de decisión** tiene el mejor desempeño en accuracy, AUC y F1. CHAID queda muy cerca (unos 40 títulos de diferencia en accuracy y 0.013 de AUC) y la **regresión multinomial** un poco más abajo.
- Los tres coinciden en las variables que más pesan: votos, tipo de título (serie o duración corta) y número de géneros, y después Drama, Thriller, Comedia y la clasificación por edad.
- Alta y Baja se separan mejor (AUC por clase de 0.80 a 0.83) que Media (0.72 a 0.76). El recall de Media es el más bajo en los tres (0.44 a 0.47).
- Ningún modelo pasa de 64% de accuracy (piso de 35.7%). Con variables de catálogo no se captura la calidad percibida. Con `Hidden Gem Score` el árbol llegaría a 83%, pero por fuga de información.
- Si lo que importa es predecir, el árbol. Si se busca estabilidad y coeficientes fáciles de explicar, la regresión multinomial. CHAID sirve para describir segmentos, leyendo solo sus dos primeros niveles.